UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INFORMÁTICA

Anexos Digitales del Trabajo de Título

Metodología basada en procesamiento de lenguaje natural para analizar la alineación curricular de Ingeniería Informática en Chile con estándares ACM/IEEE y necesidades de la industria

Estudiante: Fabián Ibarra Norambuena
Profesor guía: Manuel Villalobos Cid

Santiago - Chile
2026

Tabla de contenidos de Anexos

Anexos **1**

Anexo A Glosario 1

Anexo B Resumen comparativo de trabajos relacionados sobre alineación curricular automatizada. 3

Anexo C Descripción del corpus de datos 6

Anexo D Protocolo y caracterización de la muestra de datos de LinkedIn . . . 6

Anexo E Flujo de procesamiento metodológico 8

Anexo F Planificación temporal del proyecto (Carta Gantt) 8

Referencias de Anexos **9**

Anexos

Anexo A. Glosario

- **Alineación Curricular**: Grado de correspondencia, congruencia y consistencia entre los componentes de un programa educativo (tales como perfiles de egreso, planes de estudio y descriptores de asignaturas) con respecto a directrices internacionales y los requerimientos del entorno laboral.
- **Clustering (Agrupamiento)**: Técnica de aprendizaje no supervisado que consiste en agrupar un conjunto de objetos de tal manera que los miembros del mismo grupo (*clúster*) sean más similares entre sí que con los de otros grupos, basándose en alguna métrica de distancia o similitud geométrica.
- **Coeficiente de Silueta (*Silhouette Coefficient*)**: Métrica de validación interna de algoritmos de *clustering* que evalúa qué tan bien agrupado está un elemento. Mide la cercanía de un objeto a su propio clúster (cohesión) frente a su cercanía a otros clústeres (separación), variando entre -1 y 1.
- **Corpus**: Conjunto estructurado y homogéneo de textos escritos, recopilado de manera sistemática para ser utilizado como base de análisis lingüístico o procesamiento computacional.
- **DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*)**: Algoritmo de agrupamiento no supervisado basado en densidad que agrupa puntos cercanos y etiqueta como valores atípicos (*outliers*) aquellos que se encuentran aislados en regiones de baja densidad.
- **Embeddings (Incrustaciones Vectoriales)**: Representaciones matemáticas de textos (palabras, frases o documentos completos) en forma de vectores densos en un espacio continuo de baja dimensionalidad, donde la cercanía geométrica de los vectores representa similitud semántica.
- **Índice de Davies-Bouldin**: Métrica de evaluación intrínseca de algoritmos de agrupamiento que calcula la similitud promedio entre cada clúster y su clúster más

similar. Valores más bajos indican agrupamientos con clústeres más compactos y mejor separados.

- **K-Means**: Algoritmo clásico de agrupamiento no supervisado que particiona un conjunto de datos en K clústeres distintos y disjuntos, asignando cada elemento al clúster cuyo centroide se encuentra a menor distancia geométrica (generalmente distancia euclidiana).

- **Lematización**: Proceso de preprocesamiento de lenguaje natural que consiste en reducir las palabras de un texto a su forma básica o raíz morfológica canonizada (lema), como infinitivos para verbos y masculino singular para adjetivos y sustantivos.

- **Procesamiento de Lenguaje Natural (PLN / NLP)**: Subcampo de la inteligencia artificial y la lingüística computacional enfocado en el diseño e implementación de algoritmos que permiten a las computadoras procesar, entender y analizar textos en lenguaje humano.

- **Sentence-Transformers (SBERT)**: Framework de aprendizaje profundo basado en redes neuronales siamesas, utilizado para adaptar modelos de lenguaje tipo BERT para generar embeddings de oraciones y textos completos de alta calidad semántica.

- **Similitud del Coseno**: Métrica matemática utilizada para cuantificar la similitud entre dos vectores en un espacio multidimensional, midiendo el coseno del ángulo formado entre ellos, independientemente de su magnitud.

- **Stop Words (Palabras Vacías)**: Términos que carecen de significado informativo relevante por sí mismos (como artículos, preposiciones y conjunciones, o en el contexto académico, términos como "asignatura", "horas" o "carrera"), que son filtrados durante el preprocesamiento de texto.

- **TF-IDF (*Term Frequency - Inverse Document Frequency*)**: Técnica estadística clásica de representación de textos que evalúa la importancia de una palabra en un documento en relación con un corpus completo, ponderándola según su frecuencia local y su rareza global.

- **t-SNE (*t-Distributed Stochastic Neighbor Embedding*)**: Algoritmo no lineal de reducción de dimensionalidad utilizado principalmente para la visualización de datos de alta dimensionalidad en espacios de dos o tres dimensiones.
- **UMAP (*Uniform Manifold Approximation and Projection*)**: Algoritmo moderno de reducción de dimensionalidad no lineal fundamentado en la geometría de variedades, eficiente computacionalmente y robusto para preservar la estructura local y global de los datos.

Anexo B. Resumen comparativo de trabajos relacionados sobre alineación curricular automatizada.

Tabla 1: Análisis comparativo de objetivos, metodologías, resultados y limitaciones de la literatura de mapeo curricular.

Referencia	**Objetivo**	**Metodología**	**Resultados principales**	**Limitaciones identificadas**
(Russell E., 2024)	Automatizar el mapeo de planes de estudio hacia habilidades y ocupaciones de la industria utilizando descripciones de cursos.	Procesamiento de Lenguaje Natural (NLP) usando SkillNER, extracción de características con ponderación TF-IDF y similitud del coseno para emparejar con O*NET.	Extracción promedio de 5.3 a 10.4 habilidades por curso. Fuerte precisión (precision@5 del 60 % al 100 %). Fuerte señal de habilidades incluso en textos breves.	Evaluación limitada a un campo (ciencia de datos) y dos instituciones. Falsos positivos por coincidencia léxica. Falta información sobre la profundidad de la habilidad enseñada.
(Xu et al., 2025a)	Evaluar el rendimiento de LLM frente a métodos NLP tradicionales en la extracción de habilidades para la analítica curricular.	Comparación de estrategias: Generación Aumentada por Recuperación (RAG), prompting Zero-shot (GPT, Llama, Gemini, Claude), modelos basados en embeddings (SBERT) y TF-IDF en 400 documentos.	RAG fue la estrategia con mejor desempeño en todos los documentos. El prompting Zero-shot tuvo peor rendimiento que métodos NLP tradicionales en la mayoría de los casos.	El rendimiento varía significativamente según el modelo seleccionado y las estrategias de prompting. Requiere diseño y ajuste cuidado antes de implementaciones a gran escala.
(Xu et al., 2025b)	Evaluar el rol de la IA Generativa (LLMs) como co-revisor curricular para generar mapeos ponderados de habilidades en evaluaciones.	Uso de GPT-4.0 frente a métodos ML (BERT, TF-IDF) para mapear 7 habilidades empresariales. Uso del alfa de Krippendorff para comparar resultados con el juicio de expertos.	Los mapeos generados por LLM se alinearon más con el juicio experto (alfa 0.76) que los métodos ML (0.65). Alta precisión en competencias como Comunicación Oral y Trabajo en Equipo.	Limitado a un solo LLM y programa de estudios. Desempeño débil en habilidades que se infieren del contexto (ej. Comunicación escrita) y no se detallan en el texto.
(Fan and Chiong, 2023)	Identificar capacidades digitales evaluadas en rúbricas de cursos universitarios de manera automatizada utilizando Machine Learning.	Extracción de características mediante TF-IDF. Comparación de clasificadores: Redes Neuronales (ANN), Máquinas de Vectores de Soporte (SVM), Random Forest y XGBoost.	SVM obtuvo el mejor rendimiento (exactitud 0.8535 y F1-score 0.8338). El rendimiento mejora y luego decae al aumentar las características extraídas.	Dependencia de la intervención humana para etiquetar los datos de entrenamiento (solo 1.735 muestras etiquetadas). Los algoritmos probados no pueden utilizar pesos difusos para mitigar ruido.

Tabla 1: Análisis comparativo de objetivos, metodologías, resultados y limitaciones de la literatura de mapeo curricular.

Referencia	**Objetivo**	**Metodología**	**Resultados principales**	**Limitaciones identificadas**
(Duarte et al., 2023)	Generar representaciones visuales comprensibles de los planes de estudio para reducir brechas de comunicación entre los actores.	Clasificación usando índices de Wikipedia, NLP (tokenización y normalización), y visualización mediante ideogramas circulares y grafos de red.	El mapeo apoyó con evidencia visual las debilidades del programa. Las representaciones cuantitativas empoderan el entendimiento entre diferentes grupos de interés.	Las representaciones agrupan conceptos pero no trazan rutas de aprendizaje precisas o de precedencia detalladas, requiriendo revisión y otras herramientas para detalles exactos.
(Miura et al., 2021)	Mapear automáticamente programas educativos de ciencias de la computación frente a estándares de aprendizaje (ITSS+) para reducir costos manuales.	Representación de texto usando Bag-of-Words (BoW) y Word Embeddings (Word2Vec). Emparejamiento usando similitud del coseno y algoritmos de aprendizaje supervisado.	El aprendizaje supervisado con Word Embeddings alcanzó la mayor medida F (0.571), superando ampliamente a enfoques tradicionales como BoW (0.333) al capturar semántica abstracta.	Requiere aumentar los datos de entrenamiento y cuantificar más correctamente características ponderando partes importantes del material didáctico.
(Constantinov et al., 2015)	Ajustar un currículo de ingeniería extrayendo las demandas del mercado laboral a través de redes profesionales.	Pipeline de datos para Análisis de Redes Profesionales (PNA) con perfiles de LinkedIn. Extracción de habilidades en sílabos mediante TF-IDF y diccionarios personalizados.	El sistema identificó habilidades del plan de estudios obsoletas en la industria y habilidades muy demandadas en el trabajo que el programa académico no estaba cubriendo.	Metodología basada en diccionarios personalizados estáticos y extracción mediante palabras clave sin abordajes semánticos complejos o contextuales de modelado de lenguaje.

Anexo C. Descripción del corpus de datos

Tabla 2: Planes de estudio y asignaturas recopiladas por universidad.

Universidad	**Carrera / Programa**	**Nº Asignaturas**
Universidad de Santiago de Chile	Ingeniería de Ejecución en Computación e Informática	43
Universidad de Santiago de Chile	Ingeniería Civil en Informática	58
Universidad de Chile	Ingeniería Civil en Computación	54
Universidad Andrés bello	Ingeniería en Computación e informática	41
Universidad de Magallanes	Ingeniería en Computación e Informática	41
Universidad Tecnológica Metropolitana	Ingeniería en Informática	44
Universidad de Concepción	Ingeniería Civil Informática	54
Universidad Técnica Federico Santa María	Ingeniería en Informática	42
Pontificia Universidad Catolica de Valparaiso	Ingeniería Informática	44
DuocUC	Ingeniería Informática	33
Universidad San Sebastián	Ingeniería Civil en Informática	50
Universidad Santo Tomás	Ingeniería Civil en Informatica y Sistemas Inteligentes	60
Universidad de la Frontera	Ingeniería Civil Informática	57
Universidad del Bío-Bío	Ingeniería de Ejecución en Computación e Informática	46
Universidad de Talca	Ingeniería Civil en Computación	43
Universidad Autonoma	Ingeniería en Informática	32
Total del Corpus (16 Programas / Planes de Estudio)		**747**

Anexo D. Protocolo y caracterización de la muestra de datos de LinkedIn

Con el fin de garantizar la representatividad, validez y reproducibilidad del análisis de pertinencia laboral, se define un protocolo formal para la selección y curaduría de la muestra de ofertas de empleo provenientes de la plataforma LinkedIn:

a. **Tamaño muestral objetivo (N)**: Se establece una muestra de $N = 200$ anuncios de empleo curados y estructurados del sector tecnológico chileno.

b. **Ventana temporal de captura**: Avisos de trabajo publicados activamente entre enero de 2026 y junio de 2026.

c. **Categorías de cargos consideradas**: La selección abarca los perfiles profesionales más representativos del mercado de TI en Chile:

   - Desarrollador de Software / Ingeniero de Software (*Backend*, *Frontend*, *Fullstack*).
   - Ingeniero / Arquitecto de Datos (*Data Engineer / Architect*).
   - Científico de Datos / Analista de Inteligencia Artificial (*Data Scientist / AI Specialist*).
   - Ingeniero de Infraestructura y Operaciones (*DevOps / Cloud Engineer*).
   - Ingeniero en Ciberseguridad y Redes.
   - Arquitecto de Software y Sistemas.

d. **Criterios de inclusión y exclusión**:

   - *Inclusión*: Ofertas laborales localizadas en Chile (presencial, híbrido o remoto), con descripción detallada de funciones, requisitos técnicos explícitos y nivel de experiencia (junior, semi-senior, senior).
   - *Exclusión*: Avisos duplicados, ofertas de pasantías o prácticas profesionales no remuneradas, solicitudes con descripciones genéricas sin requerimientos tecnológicos concretos, y vacantes orientadas puramente a ventas o gestión comercial sin exigencia técnica.

e. **Protocolo de curaduría y lematización**: Extracción de textos mediante estructuración de secciones de "Requisitos" y "Responsabilidades", seguida por filtrado de palabras vacías laborales (ej. "empresa", "beneficios", "postular") y extracción de entidades tecnológicas (lenguajes, frameworks, metodologías).

f. **Cumplimiento de Términos de Servicio (ToS)**: La captura de datos se realiza en estricto cumplimiento con los Términos de Servicio de LinkedIn, utilizando información de acceso público de forma manual o mediante APIs de consulta de

vacantes públicas para fines exclusivamente de investigación académica sin fines de lucro, sin scraping masivo ni almacenamiento de datos personales identificables de reclutadores o postulantes.

Anexo E. Flujo de procesamiento metodológico

Tabla 3: Detalle de entradas, procesos y salidas del flujo metodológico mínimo.

Fase	**Entrada / Fuentes**	**Resultado / Salida**
1. Recolección	Mallas, PDF de asignaturas, estándares, LinkedIn	Documentos crudos en base de datos
2. Limpieza	Textos crudos extraídos	Textos planos limpios en minúsculas
3. Normalización	Nombres de asignaturas heterogéneos	Nombres estandarizados y homologados
4. Construcción Corpus	Textos normalizados y filtrados	Base de datos del corpus estructurado
5. Rep. Vectorial	Corpus estructurado	Vectores densos (embeddings multilingües)
6. Reducción Dim.	Vectores de alta dimensionalidad	Vectores en espacio de menor dimensión
7. Clustering	Vectores de asignaturas/perfiles	Clústeres (K-Means, Jerárquico) y Outliers (DBSCAN)
8. Similitud	Vectores y centroides de grupos	Índices de brecha y alineación semántica
9. Visualización	Métricas de alineación y clústeres	Gráficos interactivos y reportes visuales

Anexo F. Planificación temporal del proyecto (Carta Gantt)

Tabla 4: Carta Gantt con la distribución temporal de las actividades (en semanas).

Actividad / Semana	**1-2**	**3-4**	**5-6**	**7-8**	**9-10**	**11-12**	**13-14**	**15-16**
Fase 1: Recolección y comprensión	X	X						
Fase 2: Preparación de datos		X	X					
Fase 3: Modelamiento y embeddings			X	X	X			
Fase 4: Evaluación y métricas					X	X		
Fase 5: Despliegue (Dashboard)						X	X	
Redacción informe y validación	X	X	X	X	X	X	X	X

Referencias

Constantinov, C., Popescu, P. S., Poteras, C. M., and Mocanu, M. L. (2015). Preliminary results of a curriculum adjuster based on professional network analysis. In *2015 19th International Conference on System Theory, Control and Computing (ICSTCC)*, pages 860–865, Cheile Gradistei, Romania. IEEE.

Duarte, R., Lacerda Nobre, Â., Pimentel, F., and Jacquinet, M. (2023). Broader Terms Curriculum Mapping: Using Natural Language Processing and Visual-Supported Communication to Create Representative Program Planning Experiences. *Applied System Innovation*, 7(1):7.

Fan, Z. and Chiong, R. (2023). Identifying digital capabilities in university courses: An automated machine learning approach. *Education and Information Technologies*, 28(4):3937–3952.

Miura, K., Saito, D., Washizaki, H., and Fukazawa, Y. (2021). Automated Educational Program Mapping on Learning Standards in Computer Science. In *2021 IEEE 45th Annual Computers, Software, and Applications Conference (COMPSAC)*, pages 1405–1406, Madrid, Spain. IEEE.

Russell E., W. (2024). Mapping Curricula to Skills and Occupations Using Course Descriptions. In *2024 IEEE World Engineering Education Conference (EDUNINE)*, pages 1–6, Guatemala City, Guatemala. IEEE.

Xu, Z., Li, X., Huan, Y., Minaya, V., and Yu, R. (2025a). From Course to Skill: Evaluating Large Language Model Performance in Curricular Analytics. In Cristea, A. I., Walker, E., Lu, Y., Santos, O. C., and Isotani, S., editors, *Artificial Intelligence in Education*, volume 15882, pages 203–211. Springer Nature Switzerland, Cham. Series Title: Lecture Notes in Computer Science.

Xu, Z., Minaya, V., Cristea, A. I., and Yu, R. (2025b). Generative AI as a Curriculum Co-Reviewer: Evaluating LLM Skill Mapping in Higher Education. In Cristea, A. I., Walker, E., Lu, Y., Santos, O. C., and Isotani, S., editors, *Artificial Intelligence in Education:*

26th International Conference, AIED 2025, Palermo, Italy, July 22–26, 2025, Proceedings, volume 15877, pages 180–195, Cham. Springer Nature Switzerland.