UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INFORMÁTICA

Santiago, 11 de agosto de 2026

Seminario de Titulación / Propuesta de Trabajo de Titulación
Comisión Evaluadora: Prof. Pamela Landeros, Prof. Víctor Araya
Departamento de Ingeniería Informática
Universidad de Santiago de Chile
Correo electrónico de contacto: fabian.ibarra.n@usach.cl

Estimados Profesores:
Miembros de la Comisión Evaluadora

Me dirijo respetuosamente a ustedes por medio de la presente carta para expresar mi sincero agradecimiento por la detallada y rigurosa revisión realizada a la propuesta de mi Trabajo de Titulación titulado: **"Método computacional basado en procesamiento de lenguaje natural para analizar la alineación curricular de Ingeniería Informática en Chile con estándares ACM/IEEE y necesidades de la industria"**.

Las valiosas sugerencias y observaciones formuladas por la comisión han permitido precisar la terminología empleada, delimitar los objetos curriculares de análisis (centrándose en mallas curriculares y perfiles de egreso declarados), clarificar la metodología computacional de representación vectorial semántica y clustering enfocada en las diferencias de mallas, fundamentar la validez del marco de evaluación externa, y robustecer la consistencia integral del documento.

He revisado minuciosamente cada uno de los 18 puntos planteados en su evaluación y he incorporado las adecuaciones y aclaraciones correspondientes en el cuerpo del informe. A continuación, presento la respuesta punto por punto a las observaciones emitidas.

Confío en que la presente respuesta y las correcciones integradas en el escrito satisfagan plenamente las requerimientos planteados por la comisión evaluadora.

---

* Nota: Se utilizó el modelo Gemini 3.6 Flash (Medium) para la redacción del texto y no para el proceso de pensamiento/razonamiento.

Atentamente,

Fabián Ibarra Norambuena

Estudiante de Ingeniería en Ejecución en Computación e Informática

Departamento de Ingeniería Informática

Universidad de Santiago de Chile

Av. Víctor Jara 3659, Estación Central, Santiago

Carta de Respuesta a las Observaciones de la Comisión Evaluadora

A continuación se detallan las respuestas puntuales y las modificaciones incorporadas al documento de propuesta de Trabajo de Titulación en atención a cada uno de los comentarios planteados por la comisión evaluadora:

Observación #1 — Título, método computacional vs. metodología y objetos curriculares:

La propuesta se titula como: "Metodología basada en procesamiento de lenguaje natural...". Al parecer lo que está proponiendo es un ¿método computacional (en vez de una metodología) basado en PLN para analizar la "heterogeneidad de las mallas (o programas/contenidos)" de la carrera de Ingeniería Informática en Chile y compararla con estándares ACM/IEEE y necesidades de la industria?. También puede decir "heterogeneidad estructural de las mallas (o programas, etc)". Lo importante es que su escrito aclare a qué se refiere con "estructural" si es que la usa, y por sobre todo, use las palabras correctas sobre qué objeto curricular se va a realizar su análisis: ¿mallas? y/o ¿programas/contenidos? y/o ¿perfiles de egreso?, y/o ¿otros?.

Respuesta y aclaración:

a. **Distinción entre método computacional y metodología:** se concuerda plenamente con la comisión. La contribución técnica central del proyecto corresponde a un **método computacional** de procesamiento de lenguaje natural y agrupamiento semántico no supervisado, el cual se articula dentro de un marco metodológico general de evaluación curricular. Se ha precisado este matiz en la redacción del resumen, introducción y objetivos.

b. **Delimitación del objeto curricular de análisis (exclusivamente mallas curriculares y perfiles de egreso):** se eliminó la consideración de programas analíticos extensos (sílabos) y se explicita formalmente que el análisis computacional se realizará **única y exclusivamente sobre dos objetos curriculares declarados**:

   - **Mallas curriculares:** constituyen el **objeto primario de análisis computacional**. Representan la estructura modular, nomenclatura de

asignaturas, distribución de créditos, nivel semestral y grafos de prerrequisitos de cada plan de estudios.

- **Perfiles de egreso declarados:** documentos normativos e institucionales que declaran formalmente las competencias finales del egresado de cada carrera.

c. **Definición de "heterogeneidad estructural" (enfoque en diferencias de mallas):** el término "heterogeneidad estructural" se define y utiliza en el escrito refiriéndose **principalmente a las diferencias existentes entre las mallas curriculares** de las distintas universidades. Específicamente, se analiza la variación en: (a) la distribución de asignaturas y créditos entre las áreas del conocimiento, (b) la presencia o ausencia de bloques de asignaturas en el itinerario de la malla, y (c) la topología y densidad del grafo de prerrequisitos semestrales entre mallas.

Observación #2 — Alcance de "abordar la heterogeneidad" y foco en mallas curriculares:

Cuando dice "abordar la heterogeneidad existente" se entiende que usted va a desarrollar un método que mejore (o elimine) la heterogeneidad de los programas existentes. Creo que usted no va a desarrollar eso. Este párrafo dice explícitamente que su objeto curricular son los programas, pero luego dice mallas y descripciones de asignatura. ¿A qué se refiere con "descripciones"?. Luego dice que su método realizará una representación vectorial semántica de los "contenidos formativos" ¿?. Aclare bien a qué se refiere y use estas palabras en todo su escrito.

Respuesta y aclaración:

a. **Alcance del proyecto respecto a la heterogeneidad:** se aclara que el objetivo del proyecto **no es estandarizar coercitivamente ni eliminar** la diversidad de mallas en Chile. El propósito es **caracterizar, cuantificar, mapear y visibilizar** objetivamente las diferencias entre las mallas curriculares mediante evidencia basada en datos textuales. Se reemplazó la expresión "abordar la heterogeneidad" por "caracterizar y analizar cuantitativamente las diferencias de mallas curriculares".

b. **Eliminación de "descripciones" y enfoque en mallas curriculares:** se eliminaron los términos ambiguos "descripciones" y "programas analíticos". El análisis computacional procesa directamente la nomenclatura, descriptores modulares y áreas

temáticas contenidas en las **mallas curriculares** y en los **perfiles de egreso declarados**.

c. **Representación vectorial de las asignaturas de la malla:** se especifica que la "representación vectorial semántica" transforma los títulos y descriptores de cada asignatura de la malla curricular (junto a las oraciones de los perfiles de egreso) en vectores densos en un espacio latente continuo $\mathbb{R}^d$ mediante modelos de lenguaje (Sentence-Transformers).

Observación #3 — Ejemplos de patrones estructurales de mallas y perfiles formativos:

Su método computacional identificará "patrones estructurales" y "perfiles formativos". Ponga entre paréntesis ejemplos de esos "patrones estructurales" que podría identificar su método para comprender a qué se refiere con "estructural". ¿Cómo podría su método identificar estos "perfiles formativos"? Ponga entre paréntesis ejemplos de "perfiles formativos" que podrían ser identificados.

Respuesta y aclaración:

a. **Ejemplos de patrones estructurales en las mallas:** se incorporaron explícitamente en el escrito ejemplos concretos centrados en las mallas: *(e.g., mayor o menor concentración de asignaturas de ciencias básicas en los primeros semestres versus especialización temprana en la malla; profundidad de las cadenas de prerrequisitos en la línea de programación; presencia o ausencia de asignaturas explícitas de ciberseguridad, ciencia de datos o ingeniería de software en la malla).*

b. **Mecanismo de identificación de perfiles formativos desde las mallas:** las asignaturas de cada malla curricular son vectorizadas y agrupadas en el espacio semántico. El "perfil formativo computacional" de una carrera surge del análisis de densidad y centroide de las asignaturas constituyentes de su malla en las distintas regiones disciplinares.

c. **Ejemplos de perfiles formativos identificables:** se añadieron ejemplos ilustrativos entre paréntesis: *(e.g., malla con perfil orientado a desarrollo e ingeniería de software; malla con perfil enfocado en ciencia de datos e inteligencia artificial; malla con perfil de infraestructura, redes y sistemas operativos; malla con perfil de computación teórica y algoritmos).* La diferencia entre las mallas de distintas universidades refleja objetivamente la heterogeneidad del sistema nacional.

Observación #4 — Perfiles de egreso vs. perfiles formativos, espacio vectorial latente común y áreas disciplinares:

¿"Perfiles de egreso" se refiere al perfil declarado por la institución (uno por carrera)?. ¿Es lo mismo que "perfiles formativos"?. ¿Va a realizar una representación vectorial semántica del mercado laboral (LinkedIn) y de los estándares internacionales?. ¿El análisis comparativo se hace sobre los resultados que arroje su método propuesto?. Indique a qué se refiere con "áreas disciplinares" (¿provienen de los estándares, las define usted o las identifica el método?).

Respuesta y aclaración:

a. **Diferenciación entre perfil de egreso declarado y perfil formativo de la malla:**

   - **Perfil de egreso declarado:** corresponde al documento normativo e institucional único promulgado por cada universidad para su carrera.
   - **Perfil formativo de la malla:** corresponde al perfil empírico resultante del agrupamiento semántico de las asignaturas efectivamente presentes en la malla curricular. La comparación entre ambos mide la alineación entre lo que la institución *declara* en su perfil y lo que su *malla curricular* estructura modularmente.

b. **Proyección en un espacio vectorial latente común ($\mathbb{R}^d$):** efectivamente, **todas las fuentes de datos**—(1) asignaturas de mallas curriculares y perfiles de egreso, (2) estándares internacionales ACM/IEEE CS2013 y CC2020, y (3) ofertas laborales de LinkedIn—se proyectan dentro del **mismo espacio vectorial latente multilingüe**. Esto permite efectuar el análisis comparativo directamente calculando similitud de coseno ($\cos\theta$) y distancias semánticas entre vectores de asignaturas de las mallas, centroides de estándares y demandas laborales.

c. **Origen de las "áreas disciplinares":** las áreas disciplinares provienen taxonómicamente de las *Knowledge Areas (KA)* definidas formalmente en los estándares de referencia ACM/IEEE CS2013 y CC2020 (e.g., *Software Development Fundamentals*, *Information Management*, *Architecture and Organization*, *Intelligent Systems*, *Information Assurance and Security*).

Observación #5 — Definición de ACM, Ground Truth para ARI/NMI/Pureza y Métricas de Alineación:

¿Qué es la clasificación ACM?. Si se refiere a usar métricas externas como ARI y NMI, estas métricas requieren la etiqueta (clase) del conjunto de datos usado para el clustering, pero sus fuentes de datos creo que no la tienen. ¿Cómo se obtiene la clase/etiqueta de referencia?. ¿Qué métricas específicas usará para evaluar la alineación?. Aclare bien por favor.

Respuesta y aclaración:

a. **Definición de ACM:** ACM corresponde a la *Association for Computing Machinery*. En el proyecto refiere a la taxonomía formal de áreas del conocimiento del *ACM Computing Classification System (CCS)* y de las guías curriculares ACM/IEEE CS2013 y CC2020.

b. **Generación del ground truth (etiquetas de referencia) para ARI, NMI y pureza:** dado que las mallas universitarias no poseen etiquetas disciplinares de fábrica, la generación de las etiquetas de referencia se realizó mediante un **curado manual** de la totalidad de las 747 asignaturas pertenecientes a los 16 programas que forman parte del corpus del informe, clasificando cada asignatura según las 18 *Knowledge Areas* de los estándares ACM/IEEE. Esta anotación actúa como clase o etiqueta de referencia de verdad de terreno (*ground truth*) para evaluar el agrupamiento algorítmico no supervisado con ARI, NMI y pureza.

c. **Métricas específicas de evaluación de alineación de mallas:** la alineación de las mallas con los estándares y el mercado se mide mediante:

- **Similitud de coseno semántica ($\cos\theta$):** calculada entre los vectores de las asignaturas de la malla y los vectores de las *Knowledge Areas* de ACM/IEEE o de los perfiles de LinkedIn.
- **Tasa de cobertura de la malla (%Cobertura):** porcentaje de conceptos clave del estándar o del mercado representados semánticamente en las asignaturas de la malla ($\cos\theta \geq 0{,}60$).
- **Índice de brecha semántica ($1 - \cos\theta$):** distancia vectorial que cuantifica la ausencia o déficit de asignaturas en la malla respecto a requerimientos de la industria.

Observación #6 — Sección Contexto (1.1), respaldos bibliográficos en Chile y referencia CC2020:

Revise la sección "1.1 Contexto" para que las referencias citadas respalden realmente lo que menciona acerca de la desconexión entre la academia y lo requerido por el campo laboral en Chile. Lo mismo al decir: "Esta desconexión se agrava por la heterogeneidad...". ¿Con esto queda claro que usted no entregará resultados con respecto a la heterogeneidad ya que se da por sentado que ya fue analizada?. En la misma sección dice: "Para abordar esta fragmentación, organizaciones internacionales como ACM e IEEE... No obstante, su adopción en Chile ha sido desigual...". ¿Esta referencia (CC2020) realmente respalda lo que menciona de lo que pasa en Chile?

Respuesta y aclaración:

a. **Respaldos bibliográficos del contexto chileno:** se reestructuró la Sección 1.1 incorporando citas bibliográficas de estudios en el contexto de la educación superior en Chile (e.g., informe SIEF de la Subsecretaría de Educación Superior, 2025; publicaciones sobre mallas e ingeniería chilena como Díaz-Quezada, 2019, y Latuz & Piña, 2024).

b. **Aclaración sobre la heterogeneidad de mallas como premisa y objeto de medición:** se explicita en el texto que la heterogeneidad nominal y estructural de las mallas de informática en Chile (coexistencia de títulos de Ejecución, Civil, Informática, Computación) es un antecedente cualitativo documentado en la literatura nacional. Lo que este trabajo aporta como novedad **no es descubrir cualitativamente que las mallas son distintas**, sino proveer el **método computacional para medir, cuantificar semánticamente y comparar dichas diferencias de mallas de manera sistemática y reproducible**.

c. **Contextualización de la cita CC2020:** se ajustó la redacción para clarificar que *CC2020 Task Force* (2020) fundamenta el marco internacional de competencias, mientras que la adopción desigual en Chile se sustenta en los informes del Consejo Nacional de Educación (CNED) y literatura local.

Observación #7 — Motivación y fundamentación de la "Metodología Bidireccional":

Aterrice bien lo que realmente va a desarrollar ya que creo que decir que su propuesta pretende ser una metodología bidireccional entre teoría educativa y dinámica de mercado no aclara su propuesta de desarrollo real. Además aquí menciona que del ámbito académico usará directrices ACM/IEEE pero no menciona mallas/programas/perfiles. ¿Entonces su trabajo consiste en desarrollar una herramienta computacional que entregará resultados acerca del alineamiento entre "algo" de la academia y el mercado (LinkedIn) y que permitirá medir qué tan pertinentes son los planes de estudio?

Respuesta y aclaración:

a. **Aterrizaje del enfoque "bidireccional":** se reformuló la sección de motivación para precisar el alcance técnico exacto. El carácter "bidireccional" significa que el método realiza una evaluación analítica en dos vertientes complementarias:

   - **Vertiente académico-normativa (top-down):** compara la estructura y asignaturas de las mallas curriculares nacionales frente a los estándares normativos internacionales ACM/IEEE CS2013/CC2020.
   - **Vertiente mercado-laboral (bottom-up):** compara las asignaturas de las mallas y perfiles de egreso declarados frente a las demandas técnicas reales extraídas dinámicamente de vacantes laborales de LinkedIn.

b. **Insumos académicos explícitos y producto entregable:** se explicita que la fuente de datos académica comprende las mallas curriculares y perfiles de egreso declarados de 16 programas universitarios chilenos. El resultado concreto es una **herramienta computacional (pipeline analítico + dashboard web interactivo)** que procesa estos insumos y entrega índices cuantitativos de alineación, matrices de brechas de mallas y mapas semánticos.

Observación #8 — Diferencia de la propuesta con el trabajo de Russell E. (2024):

¿Cuál es la diferencia de su propuesta con el trabajo de Russell E. (2024) (mencionado en la tabla comparativa del anexo B) que no sea la cobertura del número de instituciones académicas? ¿lo que usted va a utilizar como fuente de información aumenta la profundidad de la habilidad enseñada que usó Russell?.

Respuesta y aclaración:

a. **Diferencia en cobertura geográfica y sistemática de mallas:** el trabajo de Russell et al. (2024) evalúa de forma acotada un solo campo (Ciencia de Datos) en únicamente 2 instituciones de EE.UU. Nuestra propuesta abarca el sistema de educación superior chileno en Ingeniería Informática (16 mallas curriculares, 747 asignaturas), abordando la especificidad del idioma español y la heterogeneidad de títulos locales (Civil vs. Ejecución).

b. **Mayor profundidad en el procesamiento de mallas y perfiles:** Russell et al. utilizaron únicamente descripciones breves de cursos de un párrafo con técnicas léxicas/reglas (SkillNER + TF-IDF). Nuestra propuesta utiliza modelos de lenguaje de representación contextual profunda basadas en transformadores (SBERT / MPNet) aplicados sobre los títulos y descriptores de las asignaturas de las mallas y los perfiles de egreso declarados, capturando la semántica disciplinar completa.

c. **Triangulación simultánea de tres fuentes (vs. mapeo único):** mientras Russell et al. mapean cursos de forma unidireccional hacia la base O*NET, nuestro método computacional realiza una **triangulación tripartita simultánea**: *Mallas curriculares* ↔ *Estándares ACM/IEEE* ↔ *Demanda laboral de LinkedIn.*

Observación #9 — Propósito del Dashboard y Análisis de Asignaturas de la Malla:

El propósito de su propuesta dice: "El dashboard integra mapas semánticos... para apoyar decisiones académicas operativas (actualización de contenidos prácticos)..." ¿por qué dice que los resultados que mostrará el dashboard podría apoyar decisiones como por ejemplo actualizar sus contenidos prácticos si usted va a trabajar con los nombres de las asignaturas y no con los contenidos?. Un nombre de asignatura, por ejemplo: "Base de datos" no nos dice nada acerca de las habilidades desarrolladas... Si la asignatura enseña bases de datos SQL (relacional) no estaría para nada alineado con NoSQL MongoDB.

Respuesta y aclaración:

a. **Alcance del dashboard como herramienta de apoyo humano a la toma de decisiones:** se concuerda plenamente con la observación de la comisión. Al trabajar a nivel de mallas curriculares y perfiles de egreso declarados, los resultados presentados en la plataforma constituyen exclusivamente un **insumo de apoyo para la toma de decisiones** académicas tácticas y estratégicas (tales como la identificación de vacíos o ausencias de asignaturas completas en la malla, desbalances de créditos entre áreas de la ACM y actualización de líneas formativas). Se enfatiza explícitamente que este sistema **no busca en ningún caso reemplazar el juicio de las personas, docentes ni comités académicos**, sino proveer evidencia analítica objetiva basada en datos para enriquecer y respaldar las deliberaciones humanas en los procesos de rediseño curricular.

Observación #10 — Brecha tecnológica planteada en la propuesta:

En la "Brecha tecnológica" dice "no existe una plataforma automatizada implantada que evalúe y compare objetivamente los programas de estudio". ¿Ninguno de los trabajos de la tabla que muestra en el anexo B disminuyen esta brecha?.

Respuesta y aclaración:

a. **Análisis de las soluciones de la literatura (Anexo B):** los trabajos revisados en el Anexo B abordan únicamente piezas parciales del problema. Por ejemplo: Miura et al. (2021) se acota a mapear currículos de computación hacia el estándar japonés ITSS+ en inglés; Constantinov et al. (2015) utiliza diccionarios estáticos; Fan et al. (2023) requiere etiquetado manual exhaustivo de rúbricas.

b. **Justificación de la brecha persistente:** ninguna de las soluciones existentes ofrece un **sistema integrado, automatizado, abierto y adaptado al español** que combine en una misma plataforma: (a) ingesta masiva de mallas curriculares y perfiles de egreso de educación superior, (b) mapeo semántico continuo hacia estándares internacionales (ACM/IEEE CS2013 y CC2020), (c) contraste dinámico con vacantes en tiempo real de LinkedIn, y (d) visualización mediante un dashboard interactivo enfocado en la comparación de mallas.

Observación #11 — Ambigüedad en la pregunta de investigación y "diferencias estructurales":

Su pregunta de investigación dice: ¿Cuáles son las similitudes y diferencias estructurales entre los diversos programas de Ingeniería Informática en Chile, y cómo se alinean sus perfiles formativos tanto con los estándares internacionales IEEE/ACM como con las competencias demandadas por el mercado laboral en el sector TI?. Se resolverá la ambigüedad de esta pregunta cuando resuelva los puntos anteriores. Aquí aparece un nuevo término clave "diferencias estructurales" ¿a qué se refiere?

Respuesta y aclaración:

a. **Definición precisa de "diferencias estructurales de mallas":** el término "diferencias estructurales" se refiere explícitamente en el escrito a las variaciones cuantitativas observadas entre las **mallas curriculares** en la organización de su itinerario formativo:

   - **Eje de cobertura disciplinar en la malla:** presencia y distribución diferencial de asignaturas pertenecientes a las distintas *Knowledge Areas* de los estándares ACM/IEEE en cada plan de estudios.
   - **Eje de balance modular:** proporción de asignaturas obligatorias del núcleo disciplinar versus asignaturas electivas o de formación general en la malla.

b. **Reformulación de la pregunta de investigación:** la pregunta se ajustó en la Sección 2.2 para reflejar la precisión de los términos: *"¿En qué medida difieren cuantitativamente la distribución disciplinar y la estructura de las mallas curriculares de Ingeniería Informática en Chile, y cuál es el grado de alineación semántica de sus asignaturas y perfiles de egreso declarados respecto a las directrices de los estándares internacionales ACM/IEEE (CS2013 y CC2020) y a las competencias tecnológicas demandadas por el mercado laboral local extraídas de LinkedIn?"*

Observación #12 — Enunciado del problema, tipos de planes, año de corte y mapeo con LinkedIn:

El enunciado del problema presenta una "conjetura", pero no clarifica los tipos de planes de estudio que usará (de corte tecnológico, tradicionales o ambos). ¿Usará planes que hayan sido re-diseñados hasta qué año?. Tampoco describe la relación entre asignaturas con los avisos de LinkedIn. Vuelva a formular el problema por favor.

Respuesta y aclaración:

a. **Tipos de mallas incluidas en el corpus:** se especifica en la Sección 2.2 y Anexo C que el corpus abarca **ambas modalidades de formación en informática existentes en Chile**: (a) mallas de corte tradicional de ciclo largo (*Ingeniería Civil en Informática / Computación*, 5.5 a 6 años) y (b) mallas de corte tecnológico o de ejecución (*Ingeniería de Ejecución en Computación e Informática / Ingeniería Informática*, 4 a 4.5 años).

b. **Criterio temporal y año de corte de las mallas:** se establece que el corpus considera las mallas curriculares e itinerarios formativos **vigentes y oficialmente dictados en el período 2018–2026** por las instituciones de la muestra.

c. **Mecanismo de relación entre asignaturas de la malla y avisos de LinkedIn:** las secciones de requisitos técnicos y funciones de las vacantes de LinkedIn son procesadas mediante NLP para generar vectores de requerimientos laborales $\mathbf{v}_{\text{job}}$. Dichos vectores se comparan directamente contra los vectores de las asignaturas de la malla $\mathbf{v}_{\text{asig}}$ mediante la similitud de coseno en el espacio vectorial compartido.

Observación #13 — Justificación del enfoque de agrupamiento (K-Means, Jerárquico, DBSCAN):

En la justificación del enfoque está describiendo los métodos existentes pero no justifica el método que usted utilizará: ¿por qué utilizará K-Means y no otro?. Usted menciona que "Por este motivo, este trabajo selecciona una estrategia comparativa tripartita que integra K Means, Agrupamiento Jerárquico y DBSCAN para proveer segmentaciones matemáticamente robustas y visualmente interpretables...". ¿Otros métodos de agrupamiento no lo hacen?

Respuesta y aclaración:

a. **Justificación técnica de la estrategia tripartita complementaria:** se profundizó la fundamentación en la Sección 4.1. La elección combinada de K-Means, Agrupamiento Jerárquico y DBSCAN responde a que cada algoritmo resuelve una necesidad analítica distinta e insustituible sobre las mallas curriculares:

   - **K-Means:** proporciona particiones convexas con centroides explícitos $\mathbf{c}_k$, ideales para calcular de forma directa los vectores promedio de las áreas disciplinares de la malla.
   - **Agrupamiento jerárquico (Hierarchical Clustering):** genera dendrogramas que reflejan la taxonomía anidada de las mallas y las relaciones de sub-disciplina entre asignaturas.
   - **DBSCAN:** algoritmo basado en densidad que **identifica explícitamente asignaturas atípicas o de ruido (*outliers*)**, es decir, asignaturas singulares en mallas de ciertas universidades que no encajan en grupos estándar.

b. **Ventaja de la comparación tripartita:** la combinación de los tres provee un diagnóstico integral de mallas verificado mediante métricas de concordancia intrínseca.

Observación #14 — Descripción del producto y pseudocódigo del método:
En la sección descripción del producto tiene que describir su método y el resultado entregado en su trabajo (dashboard). Como el método es computacional podría presentar por ejemplo un algoritmo en pseudocódigo que lo describa.

Respuesta y aclaración:

a. **Descripción del método computacional y dashboard de mallas:** se reestructuró la Sección 5 describiendo el pipeline algorítmico de backend (ingesta de mallas y perfiles declarados, embebido SBERT, reducción UMAP) y la arquitectura del dashboard web interactivo en React enfocado en la comparación visual de mallas curriculares.

b. **Inclusión del algoritmo en pseudocódigo:** se incorporó en la Sección 5.1 el bloque formal de algoritmo en pseudocódigo (*Algoritmo 1: Pipeline computacional de análisis semántico y comparación de mallas curriculares*), el cual se transcribe a continuación:

Algoritmo 1 Pipeline computacional de análisis semántico y comparación de mallas curriculares

Require: Corpus de mallas $\mathcal{M} = \{M_1, M_2, \ldots, M_n\}$, Perfiles de Egreso $\mathcal{P}$, Estándares $\mathcal{S}$ (ACM/IEEE KAs), Vacantes LinkedIn $\mathcal{L}$, Modelo SBERT $\mathcal{E}$

Ensure: Representaciones vectoriales, Clústeres de mallas, Matrices de Similitud S y Dashboard en React

procedure PipelineAnalisisCurricular($\mathcal{M}, \mathcal{P}, \mathcal{S}, \mathcal{L}, \mathcal{E}$)

Fase 1: Preprocesamiento y limpieza

for cada asignatura $a \in M_i \in \mathcal{M}$ **do**

$a_{\text{clean}} \leftarrow \text{NormalizarOrtografia}(\text{RemoverStopWords}(a.\text{nombre} \cup a.\text{descriptor}))$

end for

for cada $p \in \mathcal{P}$, $s \in \mathcal{S}$, $l \in \mathcal{L}$ **do**

$p_{\text{clean}} \leftarrow \text{LimpiezaTexto}(p), \quad s_{\text{clean}} \leftarrow \text{LimpiezaTexto}(s), \quad l_{\text{clean}} \leftarrow \text{LimpiezaTexto}(l)$

end for

Fase 2: Generación de embeddings multilingües

$\mathbf{V}_{\mathcal{M}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{M}_{\text{clean}}), \quad \mathbf{V}_{\mathcal{P}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{P}_{\text{clean}})$

$\mathbf{V}_{\mathcal{S}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{S}_{\text{clean}}), \quad \mathbf{V}_{\mathcal{L}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{L}_{\text{clean}})$

Fase 3: Modelamiento y agrupamiento semántico (clustering)

$\mathcal{C}_{\text{kmeans}} \leftarrow \text{KMeans}(\mathbf{V}_{\mathcal{M}}, k), \quad \mathcal{C}_{\text{hier}} \leftarrow \text{HierarchicalClustering}(\mathbf{V}_{\mathcal{M}})$

$\mathcal{O}_{\text{dbscan}} \leftarrow \text{DBSCAN}(\mathbf{V}_{\mathcal{M}}, \epsilon, \text{min_pts})$ ▷ Aislamiento de asignaturas atípicas

Fase 4: Comparación y alineación vectorial

for cada programa $M_i \in \mathcal{M}$ **do**

$S_{\text{ACM}}[i] \leftarrow \text{SimilitudCoseno}(\mathbf{V}_{M_i}, \mathbf{V}_{\mathcal{S}})$ ▷ Alineación con estándar ACM/IEEE

$S_{\text{LinkedIn}}[i] \leftarrow \text{SimilitudCoseno}(\mathbf{V}_{M_i}, \mathbf{V}_{\mathcal{L}})$ ▷ Alineación con mercado TI

$S_{\text{Perfil}}[i] \leftarrow \text{SimilitudCoseno}(\mathbf{V}_{M_i}, \mathbf{V}_{P_i})$ ▷ Alineación malla vs perfil

end for

Fase 5: Despliegue en dashboard React

Exportar matrices $\{S_{\text{ACM}}, S_{\text{LinkedIn}}, S_{\text{Perfil}}\}$ y coordenadas UMAP a formato JSON

Renderizar mapas semánticos interactivos y matrices de diferencias de mallas en React

end procedure

Observación #15 — Metodología, actividades por fase, objetivos específicos e hitos:

En su metodología "capítulo 6 o 7" debe definir claramente las actividades por fase y relacionar cada actividad con los objetivos específicos. Además, en la planificación debe indicar y describir los hitos (entregables/resultados explícitos y cuándo lo entregará) por fase.

Respuesta y aclaración:

a. **Matriz de actividades por fase relacionadas con objetivos específicos:** en las Secciones 6 y 7 se detalló de manera explícita la correspondencia 1-a-1 entre fases metodológicas, actividades técnicas y Objetivos Específicos (OE1 a OE5).

b. **Definición de hitos y entregables explícitos por fase:** se incorporó en la Sección 7 una tabla formal de **Hitos de proyecto**, con los entregables verificables centrados en el análisis de mallas curriculares y perfiles de egreso declarados:

Tabla 1: Hitos, entregables explícitos y vinculación con Objetivos Específicos.

Hito	Fase CRISP-DM	Entregable / Resultado explícito	OE	Semana
H1	1. Comprensión	Corpus crudo compilado (16 mallas curriculares, 747 asignaturas, perfiles de egreso, ACM, 200 vacantes LinkedIn).	OE1	Sem 2
H2	2. Preparación	Dataset de mallas y perfiles estructurado y normalizado en JSON/SQL.	OE1	Sem 4
H3	3. Modelamiento	Matriz de *embeddings* SBERT de asignaturas de mallas y modelo de *clustering*.	OE2, OE3	Sem 8
H4	4. Evaluación	Reporte cuantitativo de métricas (Silhouette, Davies-Bouldin, ARI, NMI) y matriz de diferencias de mallas.	OE3, OE4	Sem 12
H5	5. Despliegue	Dashboard interactivo de comparación de mallas desplegado en React y reporte de validación cualitativa por expertos.	OE4, OE5	Sem 16

Observación #16 — Coherencia entre título, pregunta de investigación, objetivos y alcance del trabajo:

En el contexto de los comentarios anteriores, se requiere verificar la coherencia entre el título del trabajo, la pregunta de investigación, el objetivo y lo declarado a hacer. En particular, los primero tres elementos parecen declarar acciones más complejas de las que es posible lograr a lo largo de un trabajo de titulación y escapan a lo que se declara como acciones concretas a realizar durante este.

Respuesta y aclaración:

a. **Alineación integral y delimitación del alcance real:** se concuerda con la apreciación de la comisión evaluadora. Se ha realizado una revisión rigurosa del documento para garantizar la perfecta alineación entre el título del trabajo, la pregunta de investigación, el objetivo general y los objetivos específicos. Se explicita formalmente que la propuesta no pretende abarcar acciones complejas de intervención o rediseño curricular amplio a nivel nacional, sino desarrollar y validar empíricamente un **método computacional analítico-descriptivo** delimitado a un corpus representativo de 16 programas de educación superior.

b. **Precisión en la redacción de objetivos y acciones concretas:** se ajustaron las formulaciones en los Capítulos 2 y 3, sustituyendo expresiones generalistas por acciones concretas, operables y medibles dentro del horizonte temporal de un trabajo de titulación: (a) estructuración del corpus de mallas curriculares y perfiles de egreso, (b) generación de representaciones vectoriales mediante Sentence-BERT, (c) análisis de agrupamiento no supervisado y cálculo de distancias semánticas, y (d) desarrollo de un dashboard interactivo como herramienta de soporte visual.

c. **Verificación de coherencia de los componentes principales:** se verificó que el título refleje fielmente la técnica computacional empleada, que la pregunta de investigación indague sobre las métricas de alineación y diferencias entre mallas, y que cada objetivo específico responda directamente a una fase metodológica con entregables verificables.

Observación #17 — Revisión del contexto, formulación del problema y comprensión del trasfondo educativo:

Se debe revisar las afirmaciones realizadas en el contexto y formulación del problemas, dado que se abordan sin un conocimiento del "negocio". Afirmar la heterogeneidad y la obsolescencia de los diseños de planes de estudio, así como la necesidad de automatizar procesos curriculares sin entender el trasfondo educativo es un problema serio de la propuesta.

Respuesta y aclaración:

a. **Revisión de juicios de valor y ajuste del tono conceptual:** se reestructuraron la Introducción (Sección 1.1) y la Formulación del Problema (Sección 2), eliminando aseveraciones sesgadas sobre la "obsolescencia" de los planes de estudio y la necesidad de una "automatización" rígida de la gestión curricular.

b. **Reconocimiento de la naturaleza del negocio educativo y la autonomía curricular:** se incorporó en el marco de la propuesta la consideración pedagógica e institucional del trasfondo educativo. Se explicita que la diversidad o heterogeneidad entre mallas curriculares responde legítimamente a la autonomía universitaria, a sellos formativos institucionales y a modelos educativos diferenciados (e.g., enfoque investigativo vs. tecnológico aplicativo), y no necesariamente a deficiencias del sistema.

c. **Rol del método computacional como insumo de apoyo human-in-the-loop:** se reformuló la utilidad del método computacional propuesto: este no pretende reemplazar los procesos reflexivos de diseño curricular ni la labor de las comisiones académicas, sino servir como un **instrumento de análisis descriptivo basado en evidencia empírica**, orientado a facilitar diagnósticos objetivos y visibilizar patrones de contenido para la deliberación informada de los especialistas educativos.

Observación #18 — Criterios de selección de convocatorias de LinkedIn e inclusión de diversos sectores:

Se debe precisar los criterios de selección de las 200 convocatorias laborales de LinkedIn. Se considera importante incluir ofertas del mundo TI así como de empresas que su ámbito de trabajo sea distinto.

Respuesta y aclaración:

a. **Explicitación de los criterios de selección y muestreo:** se detallaron en la Sección 4.1 y Anexo C los criterios sistemáticos de inclusión para las 200 convocatorias laborales recolectadas de LinkedIn: (a) ofertas publicadas en Chile durante el periodo 2024–2026, (b) presencia explícita de requisitos técnicos, competencias exigidas y descripción del rol, (c) ofertas dirigidas a perfiles del ámbito de la computación e informática (desarrollo de software, análisis de datos, ciberseguridad, infraestructura TI, gestión de proyectos tecnológicos), y (d) eliminación de ofertas duplicadas o ambiguas.

b. **Estratificación de la muestra (sector TI vs. empresas no-TI):** atendiendo al requerimiento de la comisión, se equilibró la muestra de 200 convocatorias dividiéndola formalmente en dos grandes estratos:

   - **Sector tecnológico (mundo TI):** vacantes provenientes de empresas cuyo giro principal es la tecnología, desarrollo de software, consultoría TI e integración de sistemas (e.g., empresas de software, consultoras TI, startups tecnológicas).
   - **Sector no-TI (industria usuaria de tecnologías):** vacantes de gerencias o áreas de informática en empresas de rubros no tecnológicos (e.g., banca y servicios financieros, minería, retail, telecomunicaciones, salud y sector público).

c. **Valor del análisis comparativo estratificado:** esta diferenciación permite cuantificar si las mallas curriculares de las universidades chilenas presentan mayor alineación semántica con los requerimientos especializados de la industria del software o con las necesidades de digitalización de la industria no tecnológica tradicional.

UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE INGENIERÍA
DEPARTAMENTO DE INGENIERÍA INFORMÁTICA



Método computacional basado en procesamiento de lenguaje natural para analizar la alineación curricular de Ingeniería Informática en Chile con estándares ACM/IEEE y necesidades de la industria

Estudiante: Fabián Ibarra Norambuena
Profesor guía: Manuel Villalobos Cid

Santiago - Chile
2026

Resumen

El presente trabajo corresponde a un proyecto de **desarrollo** enfocado en caracterizar y analizar cuantitativamente las diferencias existentes en los programas de Ingeniería Informática en Chile mediante un enfoque de análisis computacional de mallas curriculares y perfiles de egreso declarados. Se propone un método computacional basado en procesamiento de lenguaje natural (Sentence-BERT) para la representación vectorial semántica de las asignaturas de las mallas y las competencias declaradas en los perfiles de egreso, junto con una estrategia tripartita de aprendizaje no supervisado (*clustering* K-Means, Jerárquico y DBSCAN) para identificar patrones estructurales de distribución disciplinar y perfiles formativos entre carreras. Adicionalmente, se incorporan métricas de similitud de coseno y tasa de cobertura proyectando en un mismo espacio vectorial latente ($\mathbb{R}^d$) los dos objetos curriculares declarados, las *Knowledge Areas* de los estándares internacionales de referencia (ACM/IEEE CS2013 y CC2020) y las competencias demandadas por el mercado laboral local extraídas de 200 vacantes de LinkedIn estratificadas entre empresas del sector tecnológico y empresas no-TI. Para evaluar la validez del agrupamiento y la alineación, se establece un marco de evaluación híbrido basado en métricas intrínsecas (Silhouette y Davies-Bouldin), validación externa contra las 18 áreas del estándar ACM mediante el curado manual de 747 asignaturas como etiqueta de referencia (*ground truth*) calculando ARI, NMI y Pureza, análisis de estabilidad mediante bootstrap y evaluación cualitativa por un panel independiente de 3 expertos. Finalmente, el pipeline algorítmico y sus resultados analíticos se operacionalizan en un tablero de control interactivo (*dashboard*) en React concebido como una herramienta de apoyo a la toma de decisiones para comités y gestores académicos.

Palabras claves: Educación en Ingeniería, Algoritmos de agrupamiento, Procesamiento de lenguaje natural, Mallas curriculares, Minería de textos, Alineación curricular.

Tabla de contenidos

1. Introducción **2**

1.1. Contexto y Motivación 2

1.2. Propósito de la solución 3

2. Planteamiento del problema **4**

2.1. Tecnologías y Brechas del Estado del Arte 4

2.2. Brecha Tecnológica 5

2.3. Enunciado y Criterios del Problema 6

3. Objetivos del proyecto **8**

3.1. Objetivo general 8

3.2. Objetivos específicos 8

4. Análisis del enfoque **11**

4.1. Representación Vectorial Contextual en Espacio Compartido 11

4.2. Justificación de la Estrategia Tripartita de Agrupamiento 11

5. Descripción del producto **13**

5.1. Flujo Metodológico e Insumos 13

5.2. Algoritmo del Método Computacional 14

5.3. Marco de Evaluación Híbrido 16

6. Metodología, herramientas y ambiente de desarrollo **17**

6.1. Justificación de la metodología a utilizar 17

6.2. Herramientas de desarrollo 17

6.3. Ambiente de desarrollo 18

7. Plan de trabajo **19**

7.1. Definición de Actividades e Hitos 19

7.2. Carta Gantt 19

Bibliografía **21**

Anexos **24**

Anexo A Glosario 24

Anexo B Resumen comparativo de trabajos relacionados sobre alineación curricular automatizada. 26

Anexo C Descripción del corpus de datos 29

Anexo D Protocolo y caracterización de la muestra de datos de LinkedIn . . . 29

Anexo E Flujo de procesamiento metodológico 31

Anexo F Planificación temporal del proyecto (Carta Gantt) 31

1. Introducción

1.1. Contexto y Motivación

En las últimas décadas, el sistema de educación superior en Chile ha alcanzado una alta cobertura y diversidad institucional en la formación en tecnología (Subsecretaría de Educación Superior, 2025). Esta expansión ha generado una marcada heterogeneidad nominal y de estructuración modular entre los planes de estudio dictados por las distintas universidades, coexistiendo programas tradicionales de ciclo largo (e.g., *Ingeniería Civil en Informática*) con carreras de corte tecnológico y de ejecución (e.g., *Ingeniería de Ejecución en Computación e Informática*) (Subsecretaría de Educación Superior, 2025; Latuz Piña, 2024). Esta diversidad curricular responde de manera legítima a la autonomía de las instituciones de educación superior, a sus distintos sellos formativos y a sus modelos pedagógicos orientados a diversos nichos del mercado laboral.

No obstante, esta variabilidad estructural dificulta la comparación cuantitativa de la oferta nacional frente a marcos de referencia internacionales. Para responder a este desafío, organizaciones como ACM e IEEE han promulgado directrices curriculares de validez global, tales como CS2013 y CC2020 (Cc2020 Task Force, 2020). Si bien estos estándares proporcionan taxonomías claras de áreas del conocimiento (*Knowledge Areas*), su adopción e integración en las mallas de las universidades chilenas ha sido desigual (Díaz-Quezada et al., 2019). A su vez, la rápida evolución tecnológica exige contrastar de forma continua las asignaturas de las mallas con la demanda técnica real del mercado laboral local.

En este escenario, los diagnósticos y rediseños curriculares han dependido tradicionalmente de revisiones manuales por comisiones académicas o encuestas de percepción cualitativas (Contreras and Perez, 2017; Díaz-Quezada et al., 2019), procesos laboriosos y susceptibles a sesgos informativos. Para apoyar esta labor, se requiere un **método computacional analítico y bidireccional** que permita procesar objetivamente los datos textuales de la oferta educativa y contrastarlos dinámicamente. El carácter **bidireccional** de este enfoque abarca dos vertientes analíticas complementarias:

a) **Vertiente Académico-Normativa (Top-Down):** Evalúa cuantitativamente la densidad y cobertura disciplinar de las asignaturas de las mallas curriculares frente

a las directrices de los estándares internacionales ACM/IEEE CS2013 y CC2020.

b) **Vertiente Mercado-Laboral (Bottom-Up):** Mide la alineación semántica entre las mallas curriculares y las demandas tecnológicas extraídas en tiempo real desde 200 vacantes laborales de LinkedIn, estratificadas formalmente entre empresas del sector tecnológico (Mundo TI) e industrias usuarias no tecnológicas (banca, minería, retail, servicios públicos).

Para asegurar un análisis delimitado y transparente, el método computacional procesa **única y exclusivamente dos objetos curriculares declarados**: (1) las **mallas curriculares** (títulos, descriptores modulares, distribución de créditos y prerrequisitos de 747 asignaturas), y (2) los **perfiles de egreso declarados** por cada una de las 16 carreras universitarias que componen el corpus de estudio (Anexo C).

1.2. Propósito de la solución

El propósito de este trabajo es proyectar y desarrollar un **método computacional** basado en procesamiento de lenguaje natural (*Sentence-Transformers*) y algoritmos de agrupamiento no supervisado (*clustering* K-Means, Jerárquico y DBSCAN) proyectados dentro de un mismo espacio vectorial latente ($\mathbb{R}^d$). Este método permite caracterizar, mapear y cuantificar numéricamente las diferencias de mallas y los grados de alineación respecto a estándares y vacantes de empleo de LinkedIn (Anexo D).

El producto final operacionaliza el pipeline computacional mediante un tablero de control interactivo (*dashboard*) en React. Este sistema está diseñado bajo una filosofía de soporte a la decisión (*Human-in-the-Loop*), entregando a docentes, coordinadores de carrera y comisiones de rediseño curricular evidencia analítica objetiva —a través de mapas semánticos, matrices de distancia vectorial e índices de brechas— para respaldar la toma de decisiones pedagógicas sin reemplazar el juicio evaluativo humano.

2. Planteamiento del problema

2.1. Tecnologías y Brechas del Estado del Arte

El análisis computacional de la alineación entre programas académicos y demandas del mercado laboral ha evolucionado significativamente en su representación textual. Los enfoques iniciales utilizaron modelos léxicos tradicionales como TF-IDF para ponderar palabras clave en descripciones de cursos; sin embargo, estas representaciones no logran capturar relaciones semánticas complejas ni sinonimias al depender estrictamente de frecuencias léxicas (Naseem et al., 2021). Para superar esto, se adoptaron representaciones distribuidas del lenguaje (*word embeddings* como Word2Vec, GloVe y FastText), que ubican las palabras en espacios vectoriales donde la cercanía denota afinidad conceptual (Naseem et al., 2021). La evidencia empírica muestra que los *word embeddings* superan a la bolsa de palabras, logrando medidas F de alineación mayores (0.571 frente a 0.333) (Miura et al., 2021), y que clasificadores supervisados como SVM alcanzan exactitudes sobresalientes (85.35 %) en la extracción de capacidades (Fan and Chiong, 2023).

En la actualidad, los modelos de lenguaje basados en transformadores multilingües (*Sentence-Transformers* como SBERT/MPNet) permiten proyectar de manera conjunta textos en español e inglés dentro de un mismo espacio vectorial latente continuo $\mathbb{R}^d$, resolviendo las barreras idiomáticas y capturando la semántica contextual profunda (Xu et al., 2025a). Para medir la alineación en este espacio vectorial compartido, la similitud del coseno ($\cos\theta$) y las tasas de cobertura se han consolidado como métricas cuantitativas estándar (Miura et al., 2021). Asimismo, el uso coordinado de algoritmos de agrupamiento no supervisado (*clustering* K-Means, agrupamiento jerárquico y DBSCAN) permite descubrir la estructura disciplinar implícita y aislar asignaturas atípicas sin requerir etiquetado previo, evaluando la calidad geométrica mediante las métricas de Silhouette y Davies-Bouldin (Remadi et al., 2024; Fan and Chiong, 2023).

Respecto a los antecedentes de la literatura comparada (Anexo B), destaca el trabajo de Russell et al. (Russell E., 2024), quienes desarrollaron un mapeo computacional de planes de estudio hacia ocupaciones de la industria. No obstante, la solución propuesta en este escrito presenta diferencias sustanciales frente al trabajo de Russell et al.:

a) **Cobertura y Especificidad del Corpus:** Mientras Russell et al. limitaron su análisis a 2 instituciones de EE.UU. en el área acotada de Ciencia de Datos, este trabajo aborda 16 programas universitarios de educación superior en Chile (747 asignaturas), considerando el contexto multilingüe en español y la dualidad de mallas de ciclo largo (Civil) y ejecutoras.

b) **Profundidad de Representación Contextual:** Russell et al. emplearon reglas léxicas y ponderación TF-IDF sobre descripciones breves de cursos (SkillNER). En contraste, nuestro método aplica transformadores vectoriales contextuales (SBERT) sobre mallas curriculares y perfiles de egreso declarados.

c) **Triangulación Tripartita Simultánea:** A diferencia del mapeo unidireccional de Russell et al. hacia la base O*NET, nuestro método realiza una triangulación simultánea en el mismo espacio vectorial: *Mallas Curriculares* $\leftrightarrow$ *Estándares ACM/IEEE* $\leftrightarrow$ *Ofertas de LinkedIn*.

2.2. Brecha Tecnológica

En el ecosistema universitario chileno no existe una plataforma automatizada implantada que evalúe y compare objetivamente los programas de estudio. Los rediseños curriculares a nivel local dependen de extensas reuniones de comisiones académicas manuales (Contreras and Perez, 2017) o de evaluaciones puntuales por pares evaluadores externos en procesos de acreditación (Díaz-Quezada et al., 2019). Por su parte, la medición de brechas de pertinencia laboral se limita a encuestas de percepción cualitativas aplicadas a egresados y empleadores, propensas al sesgo subjetivo humano (Latuz Piña, 2024). A nivel metodológico, las soluciones existentes en la literatura suelen corresponder a flujos experimentales diseñados ad hoc, basados en diccionarios estáticos sin profundidad semántica (Constantinov et al., 2015) o en modelos que demandan un costoso etiquetado manual de datos (Fan and Chiong, 2023). Ninguna herramienta integra en una misma arquitectura en español la ingesta de mallas curriculares, el mapeo continuo contra la ACM y el contraste estratificado con el mercado laboral en un dashboard interactivo.

2.3. Enunciado y Criterios del Problema

A partir de la brecha identificada, se formula la siguiente **pregunta de investigación**:

> *"¿En qué medida difieren cuantitativamente la distribución disciplinar y la estructura de las mallas curriculares de Ingeniería Informática en Chile, y cuál es el grado de alineación semántica de sus asignaturas y perfiles de egreso declarados respecto a las directrices de los estándares internacionales ACM/IEEE (CS2013 y CC2020) y a las competencias tecnológicas demandadas por el mercado laboral local extraídas de LinkedIn?"*

Se concibe como **conjetura o hipótesis de trabajo** que las mallas curriculares de corte tradicional de ciclo largo (Ingeniería Civil Informática) presentan una alta alineación semántica con los contenidos fundamentales del estándar ACM/IEEE pero manifiestan brechas de cobertura frente a competencias aplicadas de alta demanda en LinkedIn, mientras que las mallas curriculares de corte tecnológico o de ejecución muestran una mayor cercanía vectorial con las vacantes del mercado laboral local pero exhiben menor densidad en las bases teóricas del estándar internacional.

Para abordar esta problemática con rigor técnico y delimitación temporal, el estudio establece los siguientes criterios metodológicos y operacionales:

1. **Delimitación de las Mallas del Corpus:** Se incluyen programas de formación universitaria vigentes y dictados oficialmente en Chile en el período 2018–2026, considerando tanto mallas de ciclo largo de 5.5 a 6 años como mallas de ejecución de 4 a 4.5 años (Anexo C).

2. **Definición de "Diferencias Estructurales de Mallas":** El análisis de variaciones estructurales se evalúa cuantitativamente a través de dos ejes principales: (a) el *Eje de Cobertura Disciplinar* (proporción de créditos y asignaturas de la malla asociados a las distintas *Knowledge Areas* de la ACM), y (b) el *Eje de Balance Modular* (relación entre el núcleo disciplinar obligatorio, líneas de especialización y materias de formación general).

3. **Mecanismo de Relación y Estratificación con LinkedIn:** La demanda laboral se modela vectorizando las secciones de requisitos y funciones de 200 vacantes publicadas en LinkedIn durante 2024–2026. Para analizar el mercado de forma representativa, la muestra se divide formalmente en dos estratos: empresas del *Sector Tecnológico (Mundo TI)* y empresas del *Sector No-TI* (industria usuaria: banca, retail, minería, salud). La alineación se calcula evaluando la similitud del coseno $\cos(\mathbf{v}_{\text{asig}}, \mathbf{v}_{\text{job}})$ entre los vectores de las asignaturas de la malla y los requerimientos del mercado.

4. **Criterios Numéricos de Decisión:** Se establecen como umbrales de validez: i) *Alineación Normativa Aceptable*: Similitud de coseno promedio $\geq$ 0,70 con las *Knowledge Areas* de la ACM y Pureza de agrupamiento $\geq$ 0,70; y ii) *Presencia de Brecha Laboral Crítica*: Distancia semántica respecto a las competencias de LinkedIn $>$ 0,40 (equivalente a similitud $\cos\theta < 0{,}60$).

3. Objetivos del proyecto

En esta sección se presentan los objetivos que guiarán el desarrollo de este trabajo. En correspondencia directa con la pregunta de investigación planteada en la Sección 2.3, se formula el objetivo general orientado a definir el alcance técnico y metodológico del proyecto. Posteriormente, se detallan los objetivos específicos que estructuran de forma secuencial y verificable las fases del desarrollo del método computacional, la preparación de los datos, el modelamiento en el espacio vectorial compartida, la validación híbrida y la transferencia de resultados.

3.1. Objetivo general

Desarrollar y evaluar un **método computacional** basado en procesamiento de lenguaje natural, representación semántica vectorial y algoritmos de agrupamiento no supervisado (*clustering*) para analizar, agrupar y comparar cuantitativamente el grado de alineación curricular de las mallas curriculares y perfiles de egreso declarados de las carreras de Ingeniería Informática en Chile con respecto a los estándares de referencia internacional (ACM/IEEE CS2013 y CC2020) y a las competencias demandadas por el mercado laboral tecnológico nacional (estratificado entre el sector TI e industrias no tecnológicas), cuantificando las diferencias estructurales y brechas formativas mediante métricas de similitud semántica en un espacio latente común $\mathbb{R}^d$, y validando los agrupamientos obtenidos mediante un marco de evaluación híbrido (cuantitativo y cualitativo).

3.2. Objetivos específicos

1. Construir un corpus curricular y de mercado estructurado, estratificado y normalizado, con el propósito de consolidar una base de datos de texto plano depurada y comparable que sirva de insumo para el análisis semántico de los programas informáticos en Chile, mediante la recopilación curada de mallas curriculares (747 asignaturas) y perfiles de egreso declarados de 16 programas universitarios chilenos, la estructuración digital de las directrices internacionales ACM/IEEE (CS2013 y CC2020), la extracción y estratificación de 200 ofertas laborales de LinkedIn (divididas entre el sector tecnológico

especializado y empresas no-TI), el curado manual de etiquetas de referencia (*ground truth*) clasificando las 747 asignaturas en las 18 *Knowledge Areas* de la ACM, y la aplicación de técnicas avanzadas de preprocesamiento NLP (remoción de *stop words* académicas, normalización ortográfica y lematización). **Criterio de calidad**: Cobertura comprobada del 100 % de las mallas y asignaturas del corpus muestral (747 asignaturas en 16 programas) con una tasa de datos corruptos o nulos $< 1{,}0\,\%$ tras la etapa de normalización y filtrado de ruido.

2. Generar representaciones vectoriales densas (*embeddings*) de los objetos curriculares y laborales en un espacio latente común ($\mathbb{R}^d$), a fin de mapear las asignaturas de las mallas, los perfiles declarados, los estándares ACM y las vacantes de mercado en una misma geometría continua que represente su semántica contextual y habilite el cálculo matemático de similitudes, utilizando modelos avanzados basados en transformadores multilingües (*Sentence-Transformers* SBERT/MPNet) en combinación con algoritmos de reducción de dimensionalidad (como UMAP o t-SNE) para su visualización espacial. **Criterio de calidad**: Conservación de la estructura topológica local del espacio vectorial verificada mediante una métrica de fidelidad de proyección (*Trustworthiness* $\geq 0{,}85$).
3. Identificar perfiles formativos específicos y medir la alineación semántica y las diferencias de mallas, con el fin de detectar patrones de especialización implícitos entre las distintas universidades y cuantificar con rigor matemático la correspondencia y las brechas curriculares frente a las directrices de referencia y las necesidades de la industria, mediante la aplicación coordinada de una estrategia tripartita de agrupamiento no supervisado (K-Means para particiones convexas con centroides explícitos, Agrupamiento Jerárquico para dendrogramas de parentesco, y DBSCAN para el aislamiento de asignaturas atípicas u *outliers*), identificando patrones estructurales *(e.g., concentración temprana de ciencias básicas vs. especialización precoz; profundidad de la línea de programación; presencia de ciberseguridad o inteligencia artificial en la malla)* y perfiles formativos *(e.g., Malla orientada a Ingeniería de Software, Malla enfocada en Ciencia de Datos, Malla de Infraestructura y Redes, Malla de Computación Teórica)*, junto al cálculo de similitud del coseno ($\cos\theta$),

tasa de cobertura (%Cobertura) e índice de brecha semántica ($1 - \cos\theta$). **Criterio de calidad**: Obtención de una partición coherente con un Coeficiente de Silhouette $\geq 0{,}25$ y un Índice de Davies-Bouldin $< 1{,}50$.

4. Validar la calidad, estabilidad y aplicabilidad práctica de los agrupamientos y brechas obtenidas, a objeto de asegurar la consistencia técnica del método computacional y la robustez de los hallazgos para su uso en la gestión académica, a través de un marco de evaluación híbrido que combine métricas cuantitativas intrínsecas, validación externa contrastada contra la taxonomía ACM utilizando el *ground truth* de 747 asignaturas etiquetadas mediante el Índice Rand Ajustado (ARI $\geq$ 0,35), Información Mutua Normalizada (NMI $\geq$ 0,40) y Pureza (Purity $\geq$ 0,70), evaluación de estabilidad mediante re-muestreo bootstrap ($\text{ARI}_{\text{promedio}} \geq 0{,}75$) y juicio cualitativo por un panel de 3 expertos independientes evaluado con un coeficiente de acuerdo inter-evaluador de Fleiss/Cohen $\kappa \geq 0{,}60$. **Criterio de calidad**: Cumplimiento simultáneo de los umbrales de validación intrínseca, externa, de estabilidad y de concordancia inter-experto estipulados.
5. Operacionalizar el método computacional y sus resultados analíticos en una interfaz interactiva de apoyo a la toma de decisiones (*Human-in-the-Loop*), para transferir el conocimiento generado a los gestores de las instituciones de educación superior y apoyar las deliberaciones informadas en los procesos de rediseño curricular continuo, mediante la implementación de un tablero de control (*dashboard*) interactivo en React que integre mapas semánticos de asignaturas de las mallas, matrices de calor de competencias y gráficos dinámicos de brechas formativas. **Criterio de calidad**: Despliegue funcional de un tablero de control navegable y responsivo con una latencia media de respuesta $< 2{,}0$ segundos por consulta interactiva y usabilidad validada sin errores críticos de renderizado.

4. Análisis del enfoque

4.1. Representación Vectorial Contextual en Espacio Compartido

Para vectorizar los textos del corpus sin sufrir las limitaciones de los modelos de bolsa de palabras (TF-IDF) ni la falta de contexto de los *word embeddings* estáticos, se seleccionan modelos de lenguaje basados en transformadores multilingües (*Sentence-Transformers* como *paraphrase-multilingual-mpnet-base-v2* o *multilingual-e5-large*). Estos modelos permiten proyectar los títulos y descriptores modulares de las asignaturas de las mallas, las oraciones de los perfiles de egreso declarados, las definiciones de las *Knowledge Areas* de la ACM/IEEE y las secciones de requerimientos de las vacantes de LinkedIn dentro de un **mismo espacio vectorial latente continuo ($\mathbb{R}^d$)**. Esta proyección homotópica habilita el cálculo directo de distancia euclidiana y similitud de coseno ($\cos\theta$) entre elementos de distintas fuentes de datos en español e inglés.

La alineación y las brechas semánticas entre una malla curricular M_i y una fuente de referencia (ACM o LinkedIn) se cuantifican mediante tres métricas principales:

a) **Similitud de Coseno ($\cos\theta$):** Mide la orientación relativa entre el vector de una asignatura $\mathbf{v}_{\text{asig}}$ y el vector de una competencia o área de conocimiento $\mathbf{v}_{\text{ref}}$:

$$\cos(\mathbf{v}_{\text{asig}}, \mathbf{v}_{\text{ref}}) = \frac{\mathbf{v}_{\text{asig}} \cdot \mathbf{v}_{\text{ref}}}{\|\mathbf{v}_{\text{asig}}\| \|\mathbf{v}_{\text{ref}}\|} \tag{1}$$

b) **Tasa de Cobertura de la Malla (%Cobertura):** Representa el porcentaje de conceptos clave o *Knowledge Areas* del estándar internacional o del mercado laboral representados en la malla curricular con una similitud semántica $\cos\theta \geq 0{,}60$.

c) **Índice de Brecha Semántica ($1 - \cos\theta$):** Cuantifica la distancia vectorial que refleja el déficit o la ausencia explícita de asignaturas en la malla curricular para cubrir requerimientos tecnológicos específicos.

4.2. Justificación de la Estrategia Tripartita de Agrupamiento

Para descubrir la estructura disciplinar de las mallas curriculares y agrupar las asignaturas de forma no supervisada, se adopta una **estrategia comparativa tripartita**

que combina K-Means, Agrupamiento Jerárquico (*Hierarchical Clustering*) y DBSCAN. Esta combinación no es arbitraria; responde a que cada algoritmo resuelve una necesidad analítica complementaria e insustituible sobre los datos curriculares:

1. **K-Means Clustering:** Produce particiones convexas en k grupos maximizando la homogeneidad interna. Su principal ventaja matemática radica en que calcula centroides explícitos $\mathbf{c}_k \in \mathbb{R}^d$ para cada clúster, los cuales actúan como la representación vectorial promedio de un área disciplinar dentro de la malla. El número óptimo de clústeres k se determina mediante la maximización del Coeficiente de Silhouette.

2. **Agrupamiento Jerárquico Aglomerativo (Ward Linkage):** Construye una estructura arborescente o dendrograma que preserva las relaciones de jerarquía y subordinación taxonómica entre asignaturas (e.g., relacionando asignaturas de programación básica con materias de ingeniería de software avanzada). Permite visualizar los niveles de abstracción disciplinar sin prefijar el número de grupos.

3. **DBSCAN (Density-Based Spatial Clustering of Applications with Noise):** Algoritmo basado en densidad que define clústeres como regiones densas de vectores en $\mathbb{R}^d$ separadas por zonas de baja densidad. Su función técnica crucial en este proyecto es la **detección y aislamiento explícito de asignaturas atípicas o ruido (*outliers*)**, es decir, asignaturas singulares presentes en mallas de ciertas universidades que no encajan en las agrupaciones estándar del sistema.

Para evaluar la validez externa de los clústeres generados frente a un estándar objetivo, se realiza una anotación manual de las 747 asignaturas del corpus clasificándolas en las 18 *Knowledge Areas* de la ACM (CS2013). Esta clasificación actúa como etiqueta de referencia (*ground truth*) para calcular el Índice Rand Ajustado (ARI $\geq 0{,}35$), la Información Mutua Normalizada (NMI $\geq 0{,}40$) y la Pureza del agrupamiento (Purity $\geq 0{,}70$).

5. Descripción del producto

Esta sección detalla la arquitectura del producto desarrollado, el cual comprende el pipeline del método computacional de análisis semántico y el tablero de control interactivo (*dashboard*) para la comparación visual de mallas curriculares.

5.1. Flujo Metodológico e Insumos

El producto se estructura en un pipeline computacional compuesto por cinco fases correlativas (detalladas en el Anexo E):

1. **Fase 1: Adquisición y Preprocesamiento:** Ingesta de mallas curriculares, perfiles de egreso declarados, estándares y vacantes; limpieza de texto, remoción de *stop words* académicas y lematización.

2. **Fase 2: Generación de Embeddings Contextuales:** Vectorización multilingüe mediante *Sentence-Transformers* (SBERT/MPNet) proyectando los textos en un espacio vectorial común $\mathbb{R}^d$, y reducción dimensional con UMAP/t-SNE.

3. **Fase 3: Modelamiento y Agrupamiento Semántico:** Ejecución de la estrategia tripartita de *clustering* (K-Means, Jerárquico y DBSCAN) para la identificación de patrones estructurales y asignaturas atípicas.

4. **Fase 4: Comparación y Cálculo de Brechas:** Generación de matrices de similitud de coseno ($\cos\theta$), tasas de cobertura (%Cobertura) e índices de brecha semántica.

5. **Fase 5: Despliegue en Dashboard React:** Exportación de matrices en formato JSON y renderización de mapas semánticos e indicadores interactivos.

La recolección de insumos contempla tres dimensiones rigurosamente delimitadas:

- **Dimensión Académica Nacional:** 16 mallas curriculares (747 asignaturas) e itinerarios formativos vigentes (2018–2026), junto a los perfiles de egreso declarados por las universidades (Anexo C).

- **Dimensión Normativa Internacional:** Las 18 *Knowledge Areas* y taxonomías de los estándares ACM/IEEE CS2013 y CC2020 (Cc2020 Task Force, 2020).
- **Dimensión Mercado Laboral:** $N = 200$ convocatorias de empleo recolectadas de LinkedIn (2024–2026), estratificadas formalmente entre empresas del *Sector Tecnológico (Mundo TI)* y empresas del *Sector No-TI* (banca, minería, retail, servicios públicos) (Anexo D).

5.2. Algoritmo del Método Computacional

A continuación se presenta el pseudocódigo formal que describe el funcionamiento secuencial del método computacional propuesto:

Algoritmo 2 Pipeline Computacional de Análisis Semántico y Comparación de Mallas Curriculares

Require: Corpus de mallas $\mathcal{M} = \{M_1, M_2, \ldots, M_n\}$, Perfiles de Egreso $\mathcal{P}$, Estándares $\mathcal{S}$ (ACM/IEEE KAs), Vacantes LinkedIn $\mathcal{L}$, Modelo SBERT $\mathcal{E}$

Ensure: Representaciones vectoriales, Clústeres de mallas, Matrices de Similitud S y Dashboard en React

procedure PipelineAnalisisCurricular($\mathcal{M}, \mathcal{P}, \mathcal{S}, \mathcal{L}, \mathcal{E}$)

Fase 1: Preprocesamiento y Limpieza

for cada asignatura $a \in M_i \in \mathcal{M}$ **do**

$a_{\text{clean}} \leftarrow \text{NormalizarOrtografia}(\text{RemoverStopWords}(a.\text{nombre} \cup a.\text{descriptor}))$

end for

for cada $p \in \mathcal{P}$, $s \in \mathcal{S}$, $l \in \mathcal{L}$ **do**

$p_{\text{clean}} \leftarrow \text{LimpiezaTexto}(p), \quad s_{\text{clean}} \leftarrow \text{LimpiezaTexto}(s), \quad l_{\text{clean}} \leftarrow \text{LimpiezaTexto}(l)$

end for

Fase 2: Generación de Embeddings Multilingües

$\mathbf{V}_{\mathcal{M}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{M}_{\text{clean}}), \quad \mathbf{V}_{\mathcal{P}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{P}_{\text{clean}})$

$\mathbf{V}_{\mathcal{S}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{S}_{\text{clean}}), \quad \mathbf{V}_{\mathcal{L}} \leftarrow \mathcal{E}.\text{encode}(\mathcal{L}_{\text{clean}})$

Fase 3: Modelamiento y Agrupamiento Semántico (Clustering)

$\mathcal{C}_{\text{kmeans}} \leftarrow \text{KMeans}(\mathbf{V}_{\mathcal{M}}, k), \quad \mathcal{C}_{\text{hier}} \leftarrow \text{HierarchicalClustering}(\mathbf{V}_{\mathcal{M}})$

$\mathcal{O}_{\text{dbscan}} \leftarrow \text{DBSCAN}(\mathbf{V}_{\mathcal{M}}, \epsilon, \text{min_pts})$ ▷ Aislamiento de asignaturas atípicas

Fase 4: Comparación y Alineación Vectorial

for cada programa $M_i \in \mathcal{M}$ **do**

$S_{\text{ACM}}[i] \leftarrow \text{SimilitudCoseno}(\mathbf{V}_{M_i}, \mathbf{V}_{\mathcal{S}})$ ▷ Alineación con Estándar ACM/IEEE

$S_{\text{LinkedIn}}[i] \leftarrow \text{SimilitudCoseno}(\mathbf{V}_{M_i}, \mathbf{V}_{\mathcal{L}})$ ▷ Alineación con Mercado TI / No-TI

$S_{\text{Perfil}}[i] \leftarrow \text{SimilitudCoseno}(\mathbf{V}_{M_i}, \mathbf{V}_{P_i})$ ▷ Alineación Malla vs Perfil

end for

Fase 5: Despliegue en Dashboard React

Exportar matrices $\{S_{\text{ACM}}, S_{\text{LinkedIn}}, S_{\text{Perfil}}\}$ y coordenadas UMAP a formato JSON

Renderizar mapas semánticos interactivos y matrices de diferencias de mallas en React

end procedure

5.3. Marco de Evaluación Híbrido

El marco de validación se compone de cuatro componentes complementarios:

a) **Evaluación Cuantitativa Intrínseca y Externa:** Validación geométrica con Silhouette ($\geq 0{,}25$) y Davies-Bouldin ($< 1{,}50$), y validación externa contra las 18 áreas del estándar ACM mediante el curado manual de las 747 asignaturas como etiqueta de referencia (*ground truth*), exigiendo ARI $\geq 0{,}35$, NMI $\geq 0{,}40$ y Purity $\geq 0{,}70$.

b) **Análisis de Estabilidad por Bootstrap:** Evaluación de consistencia algorítmica ($B = 100$ iteraciones sobre subconjuntos aleatorios del 80 %–90 % del corpus) asegurando $\text{ARI}_{\text{estabilidad}} \geq 0{,}75$.

c) **Evaluación Cualitativa por Panel de Expertos:** Revisión por un panel independiente de 3 expertos académicos/industriales evaluando la coherencia pedagógica con una concordancia inter-evaluador $\kappa \geq 0{,}60$.

d) **Evaluación de Usabilidad y Despliegue del Dashboard:** Verificación de latencia interactiva $< 2{,}0$ segundos en la plataforma React para garantizar su efectividad en reuniones de comisiones académicas.

6. Metodología, herramientas y ambiente de desarrollo

6.1. Justificación de la metodología a utilizar

Para estructurar y guiar el desarrollo de este proyecto, se ha seleccionado la metodología CRISP-DM (*Cross-Industry Standard Process for Data Mining*). La elección de este marco de trabajo se justifica por su enfoque iterativo y su probada eficacia en proyectos de ciencia de datos y minería de texto. CRISP-DM proporciona un ciclo de vida claro que abarca desde la comprensión del dominio educativo e industrial hasta el despliegue del *dashboard* interactivo, asegurando que cada fase del procesamiento de lenguaje natural y modelamiento no supervisado responda de manera directa a los objetivos y necesidades del problema planteado.

6.2. Herramientas de desarrollo

El procesamiento analítico y la implementación tecnológica se llevarán a cabo utilizando el lenguaje de programación Python, debido a su robusto ecosistema orientado al procesamiento de lenguaje natural y aprendizaje automático. Entre las principales librerías a utilizar destacan:

- **Procesamiento de Lenguaje Natural (NLP)**: *spaCy* y *NLTK* para las tareas de limpieza, tokenización, remoción de palabras vacías y lematización.
- **Representación Vectorial**: *Sentence-Transformers* (basado en la biblioteca *Hugging Face Transformers*) para la generación de *embeddings* semánticos.
- **Agrupamiento y Reducción de Dimensionalidad**: *scikit-learn* para algoritmos como K-Means, DBSCAN y cálculo de similitud del coseno; junto con librerías especializadas como *UMAP* y *t-SNE* para la proyección espacial de los datos.
- **Visualización y Despliegue**: *Matplotlib* y *Seaborn* para el análisis exploratorio, y *React* para la construcción de la interfaz gráfica y el tablero interactivo final.

6.3. Ambiente de desarrollo

El entorno de trabajo estará centralizado de forma nativa en el sistema operativo *Ubuntu 24.04 LTS*. Todo el desarrollo del código fuente, el diseño del *pipeline* y el empaquetado de la solución se realizarán utilizando *Visual Studio Code* (VS Code) como entorno de desarrollo integrado (IDE). Además, para garantizar la trazabilidad íntegra del proyecto, la totalidad de los archivos (tanto el código como la documentación) quedarán estrictamente versionados utilizando el sistema *Git*, con el repositorio central alojado en la plataforma *GitHub*.

7. Plan de trabajo

7.1. Definición de Actividades e Hitos

Las actividades del proyecto se estructuran temporalmente a lo largo de un semestre académico (16 semanas de trabajo), organizadas según las fases de la metodología CRISP-DM y vinculadas de forma directa con los Objetivos Específicos (OE1 a OE5).

Para garantizar la verificabilidad del avance del proyecto y la entrega oportuna de resultados, se definen cinco **Hitos de Proyecto (H1 a H5)** con sus correspondientes entregables explícitos y semanas de término, tal como se sintetiza en la Tabla 2:

Tabla 2: Hitos, entregables explícitos y vinculación con Objetivos Específicos.

Hito	**Fase CRISP-DM**	**Entregable / Resultado Explícito**	**OE**	**Semana**
H1	1. Comprensión	Corpus crudo compilado (16 mallas curriculares, 747 asignaturas, perfiles de egreso declarados, ACM, 200 vacantes de LinkedIn).	OE1	Sem 2
H2	2. Preparación	Dataset de mallas y perfiles estructurado y normalizado en JSON/SQL, y *ground truth* etiquetado de 747 asignaturas.	OE1	Sem 4
H3	3. Modelamiento	Matriz de *embeddings* SBERT de asignaturas de mallas y modelos de *clustering* (K-Means, Jerárquico, DBSCAN).	OE2, OE3	Sem 8
H4	4. Evaluación	Reporte cuantitativo de métricas (Silhouette, Davies-Bouldin, ARI, NMI, Pureza), análisis bootstrap y matriz de diferencias de mallas.	OE3, OE4	Sem 12
H5	5. Despliegue	Dashboard interactivo de comparación de mallas desplegado en React y reporte de validación cualitativa por expertos.	OE4, OE5	Sem 16

7.2. Carta Gantt

La planificación temporal detallada de las tareas, dependencias entre fases y asignación de semanas a lo largo del periodo académico se presenta en la representación

gráfica de la Carta Gantt ubicada en la Tabla del Anexo F.

Referencias

Araujo, K., Garretón, V., Figueroa, A., Salazar, M., and Piquer, J. (2023). *Chile crea futuro: Reportes de expertos para cuatro grandes fenómenos de cambio*. Consejo Nacional de Ciencia, Tecnología, Conocimiento e Innovación.

Cc2020 Task Force (2020). *Computing Curricula 2020: Paradigms for Global Computing Education*. ACM, New York, NY, USA.

Constantinov, C., Popescu, P. S., Poteras, C. M., and Mocanu, M. L. (2015). Preliminary results of a curriculum adjuster based on professional network analysis. In *2015 19th International Conference on System Theory, Control and Computing (ICSTCC)*, pages 860–865, Cheile Gradistei, Romania. IEEE.

Contreras, M. V. and Perez, G. (2017). Diseño y evaluación de una asignatura de integración curricular para ingenieros de primer ciclo de formación a partir de Project-Oriented Learning. *Revista de Educación en Ingeniería*, 12(24):45–56.

Díaz-Quezada, V., Poblete-Letelier, Á., and Gallardo-González, M. (2019). Rediseño curricular por competencias: experiencia en la formación inicial universitaria en Chile. *Revista Iberoamericana de Educación Superior*, pages 72–91.

Duarte, R., Lacerda Nobre, Â., Pimentel, F., and Jacquinet, M. (2023). Broader Terms Curriculum Mapping: Using Natural Language Processing and Visual-Supported Communication to Create Representative Program Planning Experiences. *Applied System Innovation*, 7(1):7.

Fan, Z. and Chiong, R. (2023). Identifying digital capabilities in university courses: An automated machine learning approach. *Education and Information Technologies*, 28(4):3937–3952.

Latuz Piña, B. I. (2024). Inserción en la industria de nuevos ingenieros en computación. Memoria para optar al título de ingeniero civil en computación, Universidad de Chile, Facultad de Ciencias Físicas y Matemáticas, Departamento de Ciencias de la Computación, Santiago de Chile.

Miedema, D., Taipalus, T., Ajanovski, V. V., Alawini, A., Goodfellow, M., Liut, M., Peltsverger, S., and Young, T. (2025). Data Systems Education: Curriculum Recommendations, Course Syllabi, and Industry Needs. In *2024 Working Group Reports on Innovation and Technology in Computer Science Education*, pages 95–123, Milan Italy. ACM.

Miura, K., Saito, D., Washizaki, H., and Fukazawa, Y. (2021). Automated Educational Program Mapping on Learning Standards in Computer Science. In *2021 IEEE 45th Annual Computers, Software, and Applications Conference (COMPSAC)*, pages 1405–1406, Madrid, Spain. IEEE.

Naseem, U., Razzak, I., Khan, S. K., and Prasad, M. (2021). A Comprehensive Survey on Word Representation Models: From Classical to State-of-the-Art Word Representation Language Models. *ACM Transactions on Asian and Low-Resource Language Information Processing*, 20(5):1–35.

Remadi, A., El Hage, K., Hobeika, Y., and Bugiotti, F. (2024). To prompt or not to prompt: Navigating the use of Large Language Models for integrating and modeling heterogeneous data. *Data & Knowledge Engineering*, 152:102313.

Russell E., W. (2024). Mapping Curricula to Skills and Occupations Using Course Descriptions. In *2024 IEEE World Engineering Education Conference (EDUNINE)*, pages 1–6, Guatemala City, Guatemala. IEEE.

Sánchez, J. L., González, C. S., Alayon, S., and González, P. (2013). Using social networks at university: The case of school of computer science. In *2013 IEEE Global Engineering Education Conference (EDUCON)*, pages 492–496.

Subsecretaría de Educación Superior (2025). Evidencias para la Estrategia de Desarrollo de la Educación Superior en Chile. Informe técnico, Ministerio de Educación, Gobierno de Chile.

Xu, Z., Li, X., Huan, Y., Minaya, V., and Yu, R. (2025a). From Course to Skill: Evaluating Large Language Model Performance in Curricular Analytics. In Cristea, A. I., Walker, E.,

Lu, Y., Santos, O. C., and Isotani, S., editors, *Artificial Intelligence in Education*, volume 15882, pages 203–211. Springer Nature Switzerland, Cham. Series Title: Lecture Notes in Computer Science.

Xu, Z., Minaya, V., Cristea, A. I., and Yu, R. (2025b). Generative AI as a Curriculum Co-Reviewer: Evaluating LLM Skill Mapping in Higher Education. In Cristea, A. I., Walker, E., Lu, Y., Santos, O. C., and Isotani, S., editors, *Artificial Intelligence in Education: 26th International Conference, AIED 2025, Palermo, Italy, July 22–26, 2025, Proceedings*, volume 15877, pages 180–195, Cham. Springer Nature Switzerland.

Anexos

Anexo A. Glosario

- **Alineación Curricular**: Grado de correspondencia, congruencia y consistencia entre los componentes de un programa educativo (tales como perfiles de egreso, planes de estudio y descriptores de asignaturas) con respecto a directrices internacionales y los requerimientos del entorno laboral.
- **Clustering (Agrupamiento)**: Técnica de aprendizaje no supervisado que consiste en agrupar un conjunto de objetos de tal manera que los miembros del mismo grupo (*clúster*) sean más similares entre sí que con los de otros grupos, basándose en alguna métrica de distancia o similitud geométrica.
- **Coeficiente de Silueta (*Silhouette Coefficient*)**: Métrica de validación interna de algoritmos de *clustering* que evalúa qué tan bien agrupado está un elemento. Mide la cercanía de un objeto a su propio clúster (cohesión) frente a su cercanía a otros clústeres (separación), variando entre -1 y 1.
- **Corpus**: Conjunto estructurado y homogéneo de textos escritos, recopilado de manera sistemática para ser utilizado como base de análisis lingüístico o procesamiento computacional.
- **DBSCAN (*Density-Based Spatial Clustering of Applications with Noise*)**: Algoritmo de agrupamiento no supervisado basado en densidad que agrupa puntos cercanos y etiqueta como valores atípicos (*outliers*) aquellos que se encuentran aislados en regiones de baja densidad.
- **Embeddings (Incrustaciones Vectoriales)**: Representaciones matemáticas de textos (palabras, frases o documentos completos) en forma de vectores densos en un espacio continuo de baja dimensionalidad, donde la cercanía geométrica de los vectores representa similitud semántica.
- **Índice de Davies-Bouldin**: Métrica de evaluación intrínseca de algoritmos de agrupamiento que calcula la similitud promedio entre cada clúster y su clúster más

similar. Valores más bajos indican agrupamientos con clústeres más compactos y mejor separados.

- **K-Means**: Algoritmo clásico de agrupamiento no supervisado que particiona un conjunto de datos en K clústeres distintos y disjuntos, asignando cada elemento al clúster cuyo centroide se encuentra a menor distancia geométrica (generalmente distancia euclidiana).

- **Lematización**: Proceso de preprocesamiento de lenguaje natural que consiste en reducir las palabras de un texto a su forma básica o raíz morfológica canonizada (lema), como infinitivos para verbos y masculino singular para adjetivos y sustantivos.

- **Procesamiento de Lenguaje Natural (PLN / NLP)**: Subcampo de la inteligencia artificial y la lingüística computacional enfocado en el diseño e implementación de algoritmos que permiten a las computadoras procesar, entender y analizar textos en lenguaje humano.

- **Sentence-Transformers (SBERT)**: Framework de aprendizaje profundo basado en redes neuronales siamesas, utilizado para adaptar modelos de lenguaje tipo BERT para generar embeddings de oraciones y textos completos de alta calidad semántica.

- **Similitud del Coseno**: Métrica matemática utilizada para cuantificar la similitud entre dos vectores en un espacio multidimensional, midiendo el coseno del ángulo formado entre ellos, independientemente de su magnitud.

- **Stop Words (Palabras Vacías)**: Términos que carecen de significado informativo relevante por sí mismos (como artículos, preposiciones y conjunciones, o en el contexto académico, términos como "asignatura", "horas" o "carrera"), que son filtrados durante el preprocesamiento de texto.

- **TF-IDF (*Term Frequency - Inverse Document Frequency*)**: Técnica estadística clásica de representación de textos que evalúa la importancia de una palabra en un documento en relación con un corpus completo, ponderándola según su frecuencia local y su rareza global.

- **t-SNE (*t-Distributed Stochastic Neighbor Embedding*)**: Algoritmo no lineal de reducción de dimensionalidad utilizado principalmente para la visualización de datos de alta dimensionalidad en espacios de dos o tres dimensiones.
- **UMAP (*Uniform Manifold Approximation and Projection*)**: Algoritmo moderno de reducción de dimensionalidad no lineal fundamentado en la geometría de variedades, eficiente computacionalmente y robusto para preservar la estructura local y global de los datos.

Anexo B. Resumen comparativo de trabajos relacionados sobre alineación curricular automatizada.

Tabla 3: Análisis comparativo de objetivos, metodologías, resultados y limitaciones de la literatura de mapeo curricular.

Referencia	**Objetivo**	**Metodología**	**Resultados principales**	**Limitaciones identificadas**
(Russell E., 2024)	Automatizar el mapeo de planes de estudio hacia habilidades y ocupaciones de la industria utilizando descripciones de cursos.	Procesamiento de Lenguaje Natural (NLP) usando SkillNER, extracción de características con ponderación TF-IDF y similitud del coseno para emparejar con O*NET.	Extracción promedio de 5.3 a 10.4 habilidades por curso. Fuerte precisión (precision@5 del 60 % al 100 %). Fuerte señal de habilidades incluso en textos breves.	Evaluación limitada a un campo (ciencia de datos) y dos instituciones. Falsos positivos por coincidencia léxica. Falta información sobre la profundidad de la habilidad enseñada.
(Xu et al., 2025a)	Evaluar el rendimiento de LLM frente a métodos NLP tradicionales en la extracción de habilidades para la analítica curricular.	Comparación de estrategias: Generación Aumentada por Recuperación (RAG), prompting Zero-shot (GPT, Llama, Gemini, Claude), modelos basados en embeddings (SBERT) y TF-IDF en 400 documentos.	RAG fue la estrategia con mejor desempeño en todos los documentos. El prompting Zero-shot tuvo peor rendimiento que métodos NLP tradicionales en la mayoría de los casos.	El rendimiento varía significativamente según el modelo seleccionado y las estrategias de prompting. Requiere diseño y ajuste cuidado antes de implementaciones a gran escala.
(Xu et al., 2025b)	Evaluar el rol de la IA Generativa (LLMs) como co-revisor curricular para generar mapeos ponderados de habilidades en evaluaciones.	Uso de GPT-4.0 frente a métodos ML (BERT, TF-IDF) para mapear 7 habilidades empresariales. Uso del alfa de Krippendorff para comparar resultados con el juicio de expertos.	Los mapeos generados por LLM se alinearon más con el juicio experto (alfa 0.76) que los métodos ML (0.65). Alta precisión en competencias como Comunicación Oral y Trabajo en Equipo.	Limitado a un solo LLM y programa de estudios. Desempeño débil en habilidades que se infieren del contexto (ej. Comunicación escrita) y no se detallan en el texto.
(Fan and Chiong, 2023)	Identificar capacidades digitales evaluadas en rúbricas de cursos universitarios de manera automatizada utilizando Machine Learning.	Extracción de características mediante TF-IDF. Comparación de clasificadores: Redes Neuronales (ANN), Máquinas de Vectores de Soporte (SVM), Random Forest y XGBoost.	SVM obtuvo el mejor rendimiento (exactitud 0.8535 y F1-score 0.8338). El rendimiento mejora y luego decae al aumentar las características extraídas.	Dependencia de la intervención humana para etiquetar los datos de entrenamiento (solo 1.735 muestras etiquetadas). Los algoritmos probados no pueden utilizar pesos difusos para mitigar ruido.

Tabla 3: Análisis comparativo de objetivos, metodologías, resultados y limitaciones de la literatura de mapeo curricular.

Referencia	**Objetivo**	**Metodología**	**Resultados principales**	**Limitaciones identificadas**
(Duarte et al., 2023)	Generar representaciones visuales comprensibles de los planes de estudio para reducir brechas de comunicación entre los actores.	Clasificación usando índices de Wikipedia, NLP (tokenización y normalización), y visualización mediante ideogramas circulares y grafos de red.	El mapeo apoyó con evidencia visual las debilidades del programa. Las representaciones cuantitativas empoderan el entendimiento entre diferentes grupos de interés.	Las representaciones agrupan conceptos pero no trazan rutas de aprendizaje precisas o de precedencia detalladas, requiriendo revisión y otras herramientas para detalles exactos.
(Miura et al., 2021)	Mapear automáticamente programas educativos de ciencias de la computación frente a estándares de aprendizaje (ITSS+) para reducir costos manuales.	Representación de texto usando Bag-of-Words (BoW) y Word Embeddings (Word2Vec). Emparejamiento usando similitud del coseno y algoritmos de aprendizaje supervisado.	El aprendizaje supervisado con Word Embeddings alcanzó la mayor medida F (0.571), superando ampliamente a enfoques tradicionales como BoW (0.333) al capturar semántica abstracta.	Requiere aumentar los datos de entrenamiento y cuantificar más correctamente características ponderando partes importantes del material didáctico.
(Constantinov et al., 2015)	Ajustar un currículo de ingeniería extrayendo las demandas del mercado laboral a través de redes profesionales.	Pipeline de datos para Análisis de Redes Profesionales (PNA) con perfiles de LinkedIn. Extracción de habilidades en sílabos mediante TF-IDF y diccionarios personalizados.	El sistema identificó habilidades del plan de estudios obsoletas en la industria y habilidades muy demandadas en el trabajo que el programa académico no estaba cubriendo.	Metodología basada en diccionarios personalizados estáticos y extracción mediante palabras clave sin abordajes semánticos complejos o contextuales de modelado de lenguaje.

Anexo C. Descripción del corpus de datos

Tabla 4: Planes de estudio y asignaturas recopiladas por universidad.

Universidad	**Carrera / Programa**	**Nº Asignaturas**
Universidad de Santiago de Chile	Ingeniería de Ejecución en Computación e Informática	43
Universidad de Santiago de Chile	Ingeniería Civil en Informática	58
Universidad de Chile	Ingeniería Civil en Computación	54
Universidad Andrés bello	Ingeniería en Computación e informática	41
Universidad de Magallanes	Ingeniería en Computación e Informática	41
Universidad Tecnológica Metropolitana	Ingeniería en Informática	44
Universidad de Concepción	Ingeniería Civil Informática	54
Universidad Técnica Federico Santa María	Ingeniería en Informática	42
Pontificia Universidad Catolica de Valparaiso	Ingeniería Informática	44
DuocUC	Ingeniería Informática	33
Universidad San Sebastián	Ingeniería Civil en Informática	50
Universidad Santo Tomás	Ingeniería Civil en Informatica y Sistemas Inteligentes	60
Universidad de la Frontera	Ingeniería Civil Informática	57
Universidad del Bío-Bío	Ingeniería de Ejecución en Computación e Informática	46
Universidad de Talca	Ingeniería Civil en Computación	43
Universidad Autonoma	Ingeniería en Informática	32
Total del Corpus (16 Programas / Planes de Estudio)		**747**

Anexo D. Protocolo y caracterización de la muestra de datos de LinkedIn

Con el fin de garantizar la representatividad, validez y reproducibilidad del análisis de pertinencia laboral, se define un protocolo formal para la selección y curaduría de la muestra de ofertas de empleo provenientes de la plataforma LinkedIn:

a. **Tamaño y estratificación muestral objetivo** (N): Se establece una muestra total de $N = 200$ anuncios de empleo curados y estructurados recopilados en Chile

(2024–2026). Para capturar adecuadamente la diversidad de la demanda laboral local, la muestra se divide formalmente en dos estratos:

- **Sector Tecnológico (Mundo TI):** Empresas cuyo giro principal es el desarrollo de software, servicios de consultoría TI, telecomunicaciones y startups tecnológicas.
- **Sector No-TI (Industria Usuaria):** Empresas de sectores tradicionales (banca e instituciones financieras, minería, retail, salud, energía y servicios públicos) que requieren perfiles informáticos para sus departamentos de tecnología interna y transformación digital.

b. **Ventana temporal de captura**: Avisos de trabajo publicados activamente entre enero de 2024 y junio de 2026.

c. **Categorías de cargos consideradas**: La selección abarca los perfiles profesionales más representativos del mercado de TI en Chile:

- Desarrollador de Software / Ingeniero de Software (*Backend*, *Frontend*, *Fullstack*).
- Ingeniero / Arquitecto de Datos (*Data Engineer / Architect*).
- Científico de Datos / Analista de Inteligencia Artificial (*Data Scientist / AI Specialist*).
- Ingeniero de Infraestructura y Operaciones (*DevOps / Cloud Engineer*).
- Ingeniero en Ciberseguridad y Redes.
- Arquitecto de Software y Sistemas.

d. **Criterios de inclusión y exclusión**:

- *Inclusión*: Ofertas laborales localizadas en Chile (presencial, híbrido o remoto), con descripción detallada de funciones, requisitos técnicos explícitos y nivel de experiencia (junior, semi-senior, senior).
- *Exclusión*: Avisos duplicados, ofertas de pasantías o prácticas profesionales no remuneradas, solicitudes con descripciones genéricas sin requerimientos

tecnológicos concretos, y vacantes orientadas puramente a ventas o gestión comercial sin exigencia técnica.

e. **Protocolo de curaduría y lematización**: Extracción de textos mediante estructuración de secciones de "Requisitos" y "Responsabilidades", seguida por filtrado de palabras vacías laborales (ej. "empresa", "beneficios", "postular") y extracción de entidades tecnológicas (lenguajes, frameworks, metodologías).

f. **Cumplimiento de Términos de Servicio (ToS)**: La captura de datos se realiza en estricto cumplimiento con los Términos de Servicio de LinkedIn, utilizando información de acceso público de forma manual o mediante APIs de consulta de vacantes públicas para fines exclusivamente de investigación académica sin fines de lucro, sin scraping masivo ni almacenamiento de datos personales identificables de reclutadores o postulantes.

Anexo E. Flujo de procesamiento metodológico

Tabla 5: Detalle de entradas, procesos y salidas del flujo metodológico mínimo.

Fase	**Entrada / Fuentes**	**Resultado / Salida**
1. Recolección	Mallas, PDF de asignaturas, estándares, LinkedIn	Documentos crudos en base de datos
2. Limpieza	Textos crudos extraídos	Textos planos limpios en minúsculas
3. Normalización	Nombres de asignaturas heterogéneos	Nombres estandarizados y homologados
4. Construcción Corpus	Textos normalizados y filtrados	Base de datos del corpus estructurado
5. Rep. Vectorial	Corpus estructurado	Vectores densos (embeddings multilingües)
6. Reducción Dim.	Vectores de alta dimensionalidad	Vectores en espacio de menor dimensión
7. Clustering	Vectores de asignaturas/perfiles	Clústeres (K-Means, Jerárquico) y Outliers (DBSCAN)
8. Similitud	Vectores y centroides de grupos	Índices de brecha y alineación semántica
9. Visualización	Métricas de alineación y clústeres	Gráficos interactivos y reportes visuales

Anexo F. Planificación temporal del proyecto (Carta Gantt)

Tabla 6: Carta Gantt con la distribución temporal de las actividades (en semanas).

Actividad / Semana	**1-2**	**3-4**	**5-6**	**7-8**	**9-10**	**11-12**	**13-14**	**15-16**
Fase 1: Recolección y comprensión	X	X						
Fase 2: Preparación de datos		X	X					
Fase 3: Modelamiento y embeddings			X	X	X			
Fase 4: Evaluación y métricas					X	X		
Fase 5: Despliegue (Dashboard)						X	X	
Redacción informe y validación	X	X	X	X	X	X	X	X